

Univerzitet u Beogradu
Matematički fakultet



Stefan Jevtić

Analiza ponavljajućih sekvenci u nukleotidnim
sekvencama hantavirusa

seminarski rad

Beograd, 2026.

Sadržaj

1	Uvod	2
2	Metodologija i opis podataka	3
2.1	Filtriranje podataka	4
2.2	Izgradnja binarne matrice ponavljajućih nizova iz izlaza alata StatRepeats	4
2.3	Korišćeni skupovi podataka	4
3	Preprocesiranje	5
3.1	Redukcija dimenzionalnosti preko filtriranja dužina ripita	6
3.2	TF-IDF transformacija	6
3.3	Redukcija dimenzionalnosti preko analize glavnih komponenti	7
4	Metodologija eksperimentalne evaluacije	7
4.1	Modeli klasterovanja	9
4.2	Prostor hiperparametara	9
5	Rezultati i diskusija	11
5.1	Optimalna konfiguracija modela	12
5.2	Najznačajniji ripiti koji pripadaju klasterima određenim optimalnim konfiguracijama modela K-Means, Agglomerative i BIRCH nad skupom podataka koji sadrži sve sekvence	13
5.3	Diskusija	17
6	Zaključak	19

1 Uvod

Hantavirusi predstavljaju grupu virusa koji prirodno inficiraju glodare i povremeno se prenose na ljude [1]. Infekcija kod ljudske populacije može rezultovati teškom kliničkom slikom i često smrtnim ishodom, pri čemu se manifestacije bolesti razlikuju u zavisnosti od genetskog tipa virusa i geografske lokacije. Na prostorima Amerike, infekcija dovodi do hantavirusnog kardiopulmonalnog sindroma (eng. *hantavirus cardiopulmonary syndrome* – HCPS), brzo progresivnog stanja koje pogađa pluća i srce. Sa druge strane, u Evropi i Aziji hantavirusi uzrokuju hemoragijsku groznicu sa bubrežnim sindromom (eng. *haemorrhagic fever with renal syndrome* – HFRS), koja prvenstveno oštećuje bubrege i krvne sudove.

U okviru ovog istraživanja analizirani su genetski podaci četiri vrste hantavirusa:

- *Hantaan virus* (lat. *Orthohantavirus hantanense*): Prvi izolovani virus iz ove grupe, koji se primarno povezuje sa teškim oblicima hemoragijske groznice sa bubrežnim sindromom. Prenosi se preko glodara domaćina i ima značajan epidemiološki uticaj u istočnoj Aziji
- *Dobrava-Belgrade virus* (lat. *Orthohantavirus dobravaense*): Glavni patogen u jugoistočnoj Evropi, sa posebnim žarištem u regionu Balkana, koji kod ljudi izaziva teške kliničke oblike HFRS-a uz visoku stopu smrtnosti
- *Puumala virus* (lat. *Orthohantavirus puumalaense*): Široko rasprostranjen u severnoj i srednjoj Evropi, odgovoran za blaže oblike endemskog HFRS-a, u medicinskoj literaturi poznatog kao *nephropathia epidemica*
- *Sin Nombre virus* (lat. *Orthohantavirus sinnombreense*): Endemska vrsta u Severnoj Americi, koja uzrokuje hantavirusni kardiopulmonalni sindrom sa izrazito nepovoljnim ishodom kod obolelih

Razlikovanje između navedenih vrsta hantavirusa može se uspešno postići analizom ponavljajućih sekvenci unutar njihovih nukleotidnih nizova. Ponavljajuće sekvence predstavljaju specifične kombinacije nukleotida koje se unutar genoma pojavljuju više puta [2]. Izračunavanjem strukturnih karakteristika ovih elemenata, kao što su njihova dužina, učestalost pojavljivanja, međusobna udaljenost i entropija, dobija se jedinstveni genomski potpis (eng. *genomic signature*) specifičan za svaku posmatranu vrstu.

U ovom radu razvijen je postupak za izdvajanje i analizu pomenutih ponavljajućih sekvenci, koji obuhvata kontrolisano preprocesiranje i filtriranje podataka u svrhu prime-
ne klasterovanja [3]. Kao ključna tehnika nenadgledanog mašinskog učenja, klasterovanje podrazumeva automatsku identifikaciju unutrašnjih struktura i grupisanje podataka na osnovu njihove matematičke sličnosti. Time se sekvence sa bliskim karakteristikama smeštaju u iste klastere, dok se međusobno različite instance razdvajaju, što omogućava otkrivanje skrivenih bioloških obrazaca bez oslanjanja na unapred definisane klase.

Empirijska analiza i vrednovanje predloženih algoritama sprovedeni su nad dva konačna skupa podataka, pri čemu opšti skup sadrži sve dostupne sekvence, dok redukovani skup obuhvata isključivo kompletne genome. Kompletne sekvence definišu se kao zapisi koji sadrže celokupan i neprekidan genomski niz datog virusa, bez nedostajućih delova

ili praznina u nukleotidnom lancu. Istraživanje obuhvata sistematsku optimizaciju hiperparametara tehnikom mrežne pretrage (eng. *Grid Search*) na pet modela nenadgledanog učenja, sa i bez redukcije dimenzionalnosti, uz analizu i poređenje rezultata.


2 Metodologija i opis podataka

Skupovi podataka korišćeni u ovom istraživanju preuzeti su u obliku FASTA datoteka, koje predstavljaju tekstualni standard u bioinformatici za skladištenje nukleotidnih sekvenci. Struktura FASTA formata je dvodelna: otpočinje linijom zaglavlja koja je označena znakom *>* i sadrži jedinstveni identifikator sekvence sa pratećim metapodacima, nakon čega sledi sam tekstualni niz nukleotidnih baza (A, C, G, T/U).

Metodologija ovog rada predstavljena je kao reproduktivan i modularan eksperimentalni tok, kako bi svaka faza obrade mogla nezavisno da se proveriti, ponovi i unapredi. Poseban fokus stavljen je na uklanjanje izvora tehničkog šuma koji može narušiti kvalitet klasterovanja, kao i na očuvanje biološki relevantnog signala u završnom prostoru kolona.

Centralnu komponentu u fazi izdvajanja karakteristika čini algoritam *StatRepeats*, specijalizovani alat namenjen identifikaciji maksimalnih ponavljajućih sekvenci unutar nukleotidnih nizova. Ovaj algoritam omogućava detekciju četiri tipa repetitivnih elemenata: direktnih nekomplementarnih (*dn*), direktnih komplementarnih (*dc*), inverznih nekomplementarnih (*in*) i inverznih komplementarnih (*ic*) ponavljajućih sekvenci.

Primenom alata *StatRepeats* postignuta je precizna statistička selekcija, čime su iz skupova podataka izdvojene isključivo statistički značajne ponavljajuće sekvence filtrirane na osnovu zadate *p*-vrednosti, dok su dobijeni rezultati uspešno uobličeni i sačuvani za dalju analizu. Celokupan tok rada, od ulaznih FASTA sekvenci do vrednovanja klastera, prikazan je na Slici 1.



Slika 1: Konceptualni prikaz obradnog cevovoda korišćenog u radu, od sirovih sekvenci do završnog vrednovanja klasterovanja.

U implementacionom smislu, obradni tok je podeljen na tri programske celine: čišćenje sekvenci, izgradnju preprocesiranog skupa kolona i analitički eksperiment klasterovanja. Opisana modularnost olakšava izmenu ili zamenu pojedinačnih komponenti bez narušavanja stabilnosti ostatka sistema.

2.1 Filtriranje podataka

Najpre je bilo potrebno normalizovati FASTA zapise, pri čemu se svaka sekvencija prevodi u strogo kontrolisan alfabet nukleotida $\{A, C, G, T, U\}$. Time se eliminišu nestandardni simboli, prazne linije i strukturne nekonzistentnosti koje mogu izazvati greške prilikom obrade i dovesti do netačnog izdvajanja ponavljajućih sekvenci.

Ulazni podaci sadrže genomske sekvence klasifikovane u četiri prethodno opisane biološke vrste hantavirusa: *Orthohantavirus puumalaense*, *Orthohantavirus dobravaense*, *Orthohantavirus hantanense* i *Orthohantavirus sinnombreense*. Ograničavanje analize na ove taksonomske celine smanjuje varijabilnost skupa i omogućava primarni fokus na identifikaciju međusobnih razlika u strukturama ponavljajućih sekvenci.

Nakon čišćenja sekvenci, pokreće se pomoćna skripta koja generiše mapiranje između *Sequence_ID* identifikatora i zvaničnog naziva virusne vrste izolovanog iz FASTA zaglavlja. Ovaj korak je ključan jer obezbeđuje konzistentno i automatsko obeležavanje uzoraka tokom izgradnje skupova podataka, čime se minimizuje verovatnoća ljudske greške i osigurava potpuna ponovljivost eksperimenta.

2.2 Izgradnja binarne matrice ponavljajućih nizova iz izlaza alata StatRepeats

Sirovi tekstualni izlazi alata *StatRepeats* transformisani su u binarnu matricu prisutstva ponavljajućih nizova. Za svaku analiziranu grupu (*dn*, *dc*, *in*, *ic*) izdvojen je kombinovani ponavljajući niz (spajanjem leve i desne polovine detektovanog ponavljanja) za svaku pojedinačnu sekvencu, nakon čega je nad svim sekvencama iz posmatranog skupa formiran rečnik svih jedinstvenih ponavljajućih nizova pronađenih u bilo kojoj od njih.

Konačna matrica kolona formirana je tako da svaka vrsta odgovara jednom genomu, a svaka kolona tačno jednom jedinstvenom ponavljajućem nizu iz pomenutog rečnika, sakupljenom preko sve četiri grupe analiza. Vrednost svake ćelije je binarna: 1 ukoliko se dati ponavljajući niz javlja unutar posmatrane sekvence, i 0 u suprotnom. Usled ogromnog broja različitih ponavljajućih obrazaca u genomima hantavirusa, dobijene matrice su izuzetno visoke dimenzionalnosti i retko popunjene (eng. *sparse*), što direktno motiviše primenu TF-IDF (eng. *Term Frequency - Inverse Document Frequency*) transformacije i redukcije dimenzionalnosti opisanih u poglavlju 3. Pregled svih ključnih datoteka i njihovih uloge u ovom procesu dat je u Tabeli 1.

2.3 Korišćeni skupovi podataka

U ovom radu fokus je stavljen na identifikaciju unutrašnje strukture i grupisanje genomskih sekvenci različitih vrsta hantavirusa zasnovano na izdvajanju karakteristika njihovih ponavljajućih sekvenci. Razumevanje genomske organizacije kroz raspodelu kratkih i dugih ponavljajućih sekvenci pruža ključan uvid u evoluciju virusa, stabilnost genoma i potencijalne biološke srodnosti. U tom smislu, primena klasterovanja nad konačnim skupovima podataka omogućava otkrivanje skrivenih obrazaca i prirodnih grupisanja unutar sekvenci, bez oslanjanja na unapred definisane klase.

Za potrebe komparativne analize i evaluacije primenjene metode nenadgledanog maši-

Tabela 1: Pregled ključnih datoteka i njihove funkcionalne uloge u obradi podataka.

<i>Naziv datoteke</i>	<i>Tip</i>	<i>Uloga u cevovodu</i>
<i>all_sequences.fasta</i>	ulaz	Primarne sirove sekvence različitog stepena kompletnosti.
<i>all_sequences_clean.fasta</i>	međufaza	FASTA zapis posle stroge validacije nukleotidnog alfabeta.
<i>all_dn.txt, all_dc.txt, all_in.txt, all_ic.txt</i>	međufaza	Strukturni izlazi alata <i>StatRepeats</i> za opšti skup sekvenci.
<i>all_sequences.csv</i>	izlaz	Konačna binarna matrica ponavljajućih nizova za eksperimentalnu analizu opšteg skupa.
<i>complete_sequences.csv</i>	izlaz	Konačna binarna matrica ponavljajućih nizova za eksperimentalnu analizu kompletnog skupa.

nskog učenja, formirana su dva konačna skupa podataka izvedena iz bioinformatičke NCBI Virus baze. Prvi skup podataka, označen kao opšti skup sekvenci *all_sequences*, obuhvata parcijalne, fragmentisane i kompletne genomske sekvence, čime se testira otpornost klasterovanja na prisustvo tehničkog šuma. Drugi skup *complete_sequences* sadrži isključivo u potpunosti sekvencirane i verifikovane kompletne genome virusa, što omogućava preciznu analizu grupisanja na visokokvalitetnim biološkim podacima.

Kvantitativni uporedni prikaz oba konačna skupa dat je u Tabeli 2. Ova tabela jasno pokazuje da skup *complete_sequences* sadrži znatno manji broj uzoraka, ali istovremeno i veći broj jedinstvenih ponavljajućih nizova po uzorku, dok skup *all_sequences* poseduje veći broj uzoraka i veću raznovrsnost, što predstavlja izazov za definisanje jasnih granica među generisanim klasterima. Oba skupa su, usled ogromnog broja kolona, obrađena isključivo u retko popunjenom obliku.

Tabela 2: Uporedni pregled broja uzoraka i broja kolona (jedinstvenih ponavljajućih nizova) po skupovima podataka.


<i>Skup podataka</i>	<i>Uzoraka</i>	<i>Broj kolona (ponavljajućih nizova)</i>
<i>all_sequences</i>	7087	47135
<i>complete_sequences</i>	435	62364

3 Preprocesiranje

Pre primene algoritama klasterovanja, sproveden je proces pripreme podataka implementiran u zasebnoj jupyter svesci (*clustering-sparse.ipynb*), prilagođenoj radu sa izuzetno visokodimenzionalnim i retko popunjenim binarnim matricama ponavljajućih nizova opisanim u prethodnom poglavlju. Nad podacima su primenjene sledeće dve tehnike: TF-IDF transformacija i redukcija dimenzionalnosti.

3.1 Redukcija dimenzionalnosti preko filtriranja dužina ripita

U cilju smanjenja broja atributa i pojednostavljenja skupova podataka, analizirana je distribucija frekvencije pojavljivanja ripita u genomima u zavisnosti od njihove dužine. Na osnovu dobijenih distribucija određene su karakteristične dužine ripita koje su korišćene za dalje filtriranje podataka.




Slika 2: Raspodela dužina ripita nad skupom podataka sa svim sekvencama.

Kao što je prikazano na slici 2, kod skupa podataka koji obuhvata sve sekvence uočava se približno normalna raspodela frekvencije ripita u zavisnosti od njihove dužine. Najveća učestalost zabeležena je kod ripita dužine 16 karaktera. Na osnovu ove analize, za potrebe filtriranja odabrane su dužine od 12, 14, 16, 18 i 20 karaktera.

Na slici 3 prikazana je distribucija za skup podataka koji sadrži isključivo kompletne sekvence. I u ovom slučaju uočava se približno normalna raspodela frekvencije ripita, pri čemu su najzastupljeniji ripiti dužine 16 karaktera. Za potrebe daljeg filtriranja odabrane su dužine od 10, 12, 14, 16, 18 i 20 karaktera.

3.2 TF-IDF transformacija

Radi lakšeg poređenja genoma pomoću L_2 norme, nad retkom binarnom matricom je primenjena TF-IDF transformacija koja uzima u obzir relativnu učestalost obrazaca. Ovim se binarne vrednosti prisustva ripita zamenjuju težinskim koeficijentima pogodnim za preciznije izračunavanje euklidskih rastojanja. Ripiti koji se javljaju kod velike većine sekvenci, i time nose malu diskriminativnu vrednost, dobijaju manju težinu, dok manje učestali ripiti dobijaju veću težinu. Transformisana matrica ostaje retko popunjena tokom čitavog toka obrade, čime je izbegnuta memorijski zahtevna konverzija u gustu reprezentaciju.



Slika 3: Raspodela dužina ripita nad skupom podataka sa kompletnim sekvencama.

3.3 Redukcija dimenzionalnosti preko analize glavnih komponenti

Za dodatnu redukciju dimenzionalnosti korišćena je metoda analize glavnih komponenti (eng. *Principal Components Analysis*), gde je udeo objašnjene varijanse biran iz skupa (5%, 10%, 15%, 20%, 40%, 60%). Na osnovu kumulativnog zbira udela objašnjene varijanse, za svaki ciljani nivo varijanse određen je najmanji broj komponenti k čije zbirno učešće dostiže taj prag, nakon čega se iz već izračunate projekcije jednostavno izdvaja prvih k komponenti. Broj zadržanih komponenti po skupu podataka i ciljanom nivou varijanse dat je u Tabeli 3.

Uočljivo je da skup *complete_sequences* zahteva znatno manji broj komponenti za isti procenat objašnjene varijanse od skupa *all_sequences*, što ukazuje na veću unutrašnju homogenost ripita unutar manjeg, isključivo kompletnog skupa sekvenci.

4 Metodologija eksperimentalne evaluacije

Nakon završetka procesa preprocesiranja podataka, formiranja binarnih matrica ripita i redukcije dimenzionalnosti, sprovedena je eksperimentalna evaluacija algoritama za klasterovanje. Osnovni cilj ovog dela istraživanja bio je da se za svaki analizirani model identifikuje konfiguracija hiperparametara koja omogućava formiranje što kompaktnijih i međusobno bolje razdvojenih klastera, uz očuvanje njihove biološke interpretabilnosti.

U ovom radu kao primarni kriterijum optimizacije izabran je *Silhouette* koeficijent. Ta metrika predstavlja jednu od najčešće korišćenih mera kvaliteta klasterovanja, bu-

Tabela 3: Broj zadržanih komponenti potreban da bi kumulativna objašnjena varijansa dostigla svaki od ciljanih nivoa.

<i>Skup podataka</i>	<i>Ciljana varijansa</i>	<i>Broj komponenti</i>
all_sequences	5%	3
all_sequences	10%	6
all_sequences	15%	10
all_sequences	20%	15
all_sequences	40%	50
all_sequences	60%	50
complete_sequences	5%	1
complete_sequences	10%	2
complete_sequences	15%	3
complete_sequences	20%	4
complete_sequences	40%	19
complete_sequences	60%	50

dući da istovremeno vrednuje kompaktnost instanci unutar istog klastera i razdvojenost između klastera. Za svaku instancu računa se prosečno rastojanje do svih tačaka unutar sopstvenog klastera, kao i najmanje prosečno rastojanje do susednog klastera. Na osnovu ova dva rastojanja dobija se Silhouette vrednost iz intervala $[-1, 1]$, pri čemu vrednosti bliske jedinici ukazuju na jasno razdvojene i kompaktne klastere, vrednosti oko nule ukazuju na preklapanje grupa, dok negativne vrednosti predstavljaju indikator pogrešne dodele instanci.

Iako je Silhouette koeficijent korišćen kao osnovni kriterijum za izbor optimalnih hiperparametara, svaka dobijena konfiguracija dodatno je analizirana primenom *Davies–Bouldin* i *Calinski–Harabasz* indeksa. Davies–Bouldin indeks meri odnos između unutrašnje disperzije klastera i njihove međusobne udaljenosti, pri čemu manje vrednosti označavaju kvalitetnije klasterovanje. Sa druge strane, Calinski–Harabasz indeks procenjuje odnos međuklastera i unutarklastera disperzije, pri čemu veće vrednosti ukazuju na bolje razdvojene grupe. Kombinovanom analizom ove tri metrike obezbeđena je objektivnija procena kvaliteta dobijenih rešenja nego što bi to bilo moguće korišćenjem samo jedne evaluacione mere.

Kako bi se izbegao subjektivan izbor hiperparametara, optimizacija svih modela sprovedena je primenom tehnike mrežne pretrage. Ova metoda podrazumeva definisanje diskretnog prostora mogućih vrednosti hiperparametara za svaki algoritam, nakon čega se sistematski ispituju sve njihove kombinacije. Za svaku konfiguraciju model se izvršava nad kompletnim skupom podataka, izračunavaju se evaluacione metrike, a kao optimalno rešenje bira se konfiguracija koja ostvaruje najveću vrednost Silhouette koeficijenta. Ovakav pristup eliminiše potrebu za ručnim podešavanjem parametara i obezbeđuje reproduktivnost eksperimenta.

4.1 Modeli klasterovanja

U eksperimentu je paralelno analizirano pet modela klasterovanja koji pripadaju različitim algoritamskim paradigmama: zasnovani na podeli *K-Means*, hijerarhijski *Agglomerative Clustering* i *BIRCH*, zasnovani na gustini *DBSCAN*, te mrežno zasnovan *CLIQUE* [4, 5, 6].

- **K-Means:** Algoritam koji deli podatke u unapred definisan broj klastera minimizovanjem unutrašnje sume kvadratnih odstupanja od centroida. Efikasan za sferične strukture klastera, ali je osetljiv klastera proizvoljnog oblika i na izbor početnih centroida.
- **Agglomerative:** Hijerarhijski pristup koji počinje tako što svaku tačku posmatra kao poseban klaster i postepeno spaja najbliže parove. Zahteva veću računarsku složenost pri radu sa velikim skupovima.
- **BIRCH:** Hijerarhijski algoritam zasnovan na stablu sažetih statistika koji brzo grupiše masovne podatke u jednom prolazu. Namenjen je efikasnom skaliranju i uklanjanju šuma pre primene drugih tehnika klasterovanja.
- **DBSCAN:** Algoritam zasnovan na gustini koji formira klastera od gusto povezanih tačaka razdvojenih regionima niske gustine. Automatski detektuje proizvoljne oblike klastera i efikasno identifikuje šum bez potrebe za zadavanjem broja grupa.
- **CLIQUE:** Mrežni algoritam koji kombinuje pronalazak gusto popunjenih jedinica u podprostorima sa spajanjem susednih regija. Pogodan je za podatke visoke dimenzionalnosti jer automatski identifikuje podprostore u kojima postoje značajni klasteri.

4.2 Prostor hiperparametara

Izbor odgovarajućih hiperparametara predstavlja važan deo postupka evaluacije algoritama klasterovanja, jer njihove vrednosti mogu značajno uticati na oblik i kvalitet dobijenih klastera. Primenjena je tehnika mrežne pretrage, pri čemu je za svaki algoritam definisan unapred određen skup mogućih vrednosti relevantnih hiperparametara. Na taj način omogućeno je sistematsko poređenje različitih konfiguracija. Prostor pretrage prikazan je u tabeli 4 i korišćen je za oba posmatrana skupa podataka.

Kod algoritma K-Means kao osnovni hiperparametar variran je broj klastera *n_clusters*. Razmatrane su vrednosti 2, 3, 4, 6 i 8, čime je obuhvaćen raspon od jednostavnih podela sa malim brojem grupa do složenijih podela podataka. Ostali parametri nisu menjani tokom pretrage. Za početne pozicije centroida korišćena je metoda *k-means++*, koja omogućava izbor početnih centroida na način kojim se smanjuje zavisnost algoritma od slučajnog početnog rasporeda. Broj različitih pokretanja određen je parametrom *n_init*=10, dok je maksimalan broj iteracija jednog pokretanja ograničen na *max_iter*=300. Na ovaj način mrežna pretraga za K-Means prvenstveno ispituje uticaj broja klastera, dok su ostali parametri fiksirani kako bi se izbeglo nepotrebno proširivanje prostora pretrage.

Kod algoritma Agglomerative Clustering parametar *n_clusters* ispitivan je nad istim skupom vrednosti kao kod K-Means algoritma, odnosno 2, 3, 4, 6 i 8. Parametar *lin-*

Tabela 4: Jedinstveni prostor hiperparametara korišćen tokom mrežne pretrage za oba skupa podataka.

Model	Varirani hiperparametri
K-Means	$n_clusters=\{2,3,4,6,8\}$, $init=k\text{-means}++$, $n_init=10$, $max_iter=300$
Agglomerative Clustering	$n_clusters=\{2,3,4,6,8\}$, $linkage=\{ward, average, complete\}$, $metric=\{euclidean, cosine\}$
BIRCH	$number_clusters=\{2,3,4,6,8\}$, $diameter=\{0.1, 0.3, 0.5\}$
DBSCAN	eps =procenjeno na osnovu pravila lakta i percentila rastojanja instanci do k najbližih suseda, $neighbors=\{3,5,10\}$
CLIQUE	$amount_intervals=\{3,4\}$, $density_threshold=\{1,2\}$

kage posmatran je kroz tri mogućnosti: *ward*, *average* i *complete*. Na taj način ispitani su različiti načini određivanja udaljenosti između klastera tokom njihovog sukcesivnog spajanja. Dodatno je variran i parametar *metric*, sa vrednostima *euclidean* i *cosine*, čime je omogućeno poređenje različitih načina merenja sličnosti između uzoraka.

Za algoritam BIRCH, varirani su broj očekivanih klastera i dozvoljeni prečnik klastera. Parametar *number_clusters* uzima vrednosti 2, 3, 4, 6 i 8, čime se omogućava ispitivanje uticaja očekivanog broja grupa na konačnu podelu skupa podataka. Parametar *diameter* variran je kroz vrednosti 0.1, 0.3 i 0.5. Ovaj parametar određuje veličinu prostora koji se može obuhvatiti tokom formiranja klastera, pa njegovo povećavanje omogućava formiranje širih grupa, dok manje vrednosti nameću strože uslove pri njihovom formiranju. Kombinovanjem navedenih vrednosti ispituje se uticaj istovremenog menjanja broja klastera i njihove dozvoljene veličine.

Kod algoritma DBSCAN, varirani su parametri *eps* i *neighbors*. Za razliku od ostalih algoritama, vrednosti parametra *eps* nisu unapred fiksirane istim skupom vrednosti za sve eksperimente. Kandidati se procenjuju posebno za svaki skup podataka i svaku redukovanu reprezentaciju, na osnovu raspodele rastojanja do k -tog najbližeg suseda. Kandidati se određuju primenom heuristike zasnovane na karakterističnim percentilima te raspodele, čime se vrednost parametra prilagođava skali konkretnog prostora. Parametar *neighbors* ispituje se za vrednosti 3, 5 i 10 i određuje broj suseda koji se uzima u obzir pri proceni lokalne gustine. Ovakav pristup omogućava da se pretraga prilagodi različitim reprezentacijama podataka nastalim nakon redukcije dimenzionalnosti.

Za algoritam CLIQUE prostor pretrage je ograničen na mali broj kombinacija hiperparametara. Parametar *amount_intervals* uzima vrednosti 3 i 4 i određuje broj intervala na koje se prostor svake dimenzije deli. Parametar *density_threshold* variran je kroz vrednosti 1 i 2 i određuje uslov gustine koji ćelija prostora mora da zadovolji da bi bila razmatrana kao deo gustog područja. Veći broj intervala omogućava finiju podelu prostora, ali istovremeno povećava broj ćelija koje algoritam mora da razmatra. Zbog toga je prostor ovog dela mrežne pretrage zadržan relativno malim, posebno imajući u vidu da broj mogućih ćelija eksponencijalno raste sa brojem dimenzija.

Za svaku ispitanu kombinaciju hiperparametara algoritam je pokrenut nad odgovarajućom reprezentacijom podataka, a kvalitet dobijene podele procenjen je pomoću

Silhouette pokazatelja, Calinski–Harabasz pokazatelja i Davies–Bouldin metrika. Kao kriterijum za izbor najbolje konfiguracije korišćen je Silhouette koeficijent, dok su preostale metrike korišćene za dodatnu procenu kvaliteta odabrane podele. Na ovaj način za svaki algoritam i svaki nivo redukcije dimenzionalnosti može biti identifikovana konfiguracija koja ostvaruje najbolju vrednost izabranog kriterijuma.

5 Rezultati i diskusija

U tabeli 5 prikazane su vrednosti Silhouette koeficijenta dobijene variranjem hiperparametara algoritama klasterovanja. Kolona *Drop* označava da li su u skupu zadržani ripiti određene dužine. Kolona *Kom.* označava broj komponenti na koje je izvršena redukcija dimenzionalnosti primenom PCA metode [7]. Kada PCA nije primenjen, ova vrednost nije definisana i označena je sa “–”. Procenat prikazan u koloni *Var.* predstavlja procenat zadržane varijanse nakon primene PCA postupka.

Tabela 5: Rezultati variranja hiperparametara algoritama klasterovanja prema Silhouette koeficijentu

Skup	PCA	Drop	Var.	Kom.	K-Means	Aggl.	BIRCH	DBSCAN	CLIQUE
All	Ne	Ne	–	–	0.0571	–	–	–	–
All	Ne	Da	–	–	0.0832	–	–	–	–
All	Da	Ne	5%	3	0.6675	0.7295	0.7295	-0.0193	0.7295
All	Da	Da	5%	3	0.7829	0.7950	0.7974	0.0025	0.3440
All	Da	Ne	10%	6	0.6142	0.6431	0.6451	0.0094	0.2718
All	Da	Da	10%	5	0.7208	0.7264	0.7208	0.0605	0.7004
All	Da	Ne	15%	10	0.5453	0.5877	0.5762	0.0632	0.2319
All	Da	Da	15%	9	0.5757	0.6438	0.6415	0.1422	0.3713
All	Da	Ne	20%	15	0.4893	0.5297	0.5268	0.0861	-0.1360
All	Da	Da	20%	14	0.5461	0.5668	0.5641	0.1615	–
All	Da	Ne	40%	50	0.3019	0.3363	0.3287	0.2055	–
All	Da	Ne	60%	50	0.3019	0.3363	0.3287	0.2055	–
Complete	Ne	Ne	–	–	0.1196	–	–	–	–
Complete	Ne	Da	–	–	0.1200	–	–	–	–
Complete	Da	Ne	5%	1	0.7809	0.7809	0.7809	0.4602	–
Complete	Da	Da	5%	1	0.7795	0.7795	0.7795	0.4556	–
Complete	Da	Ne	10%	2	0.7207	0.7207	0.7207	0.5822	–
Complete	Da	Da	10%	2	0.7204	0.7148	0.7204	0.5762	–
Complete	Da	Ne	15%	3	0.7513	0.7513	0.7513	0.5281	0.3922
Complete	Da	Da	15%	3	0.7507	0.7507	0.7507	0.5309	0.3916
Complete	Da	Ne	20%	4	0.6893	0.6893	0.6931	0.4676	0.3574
Complete	Da	Ne	40%	19	0.4510	0.4088	0.3384	0.6077	–
Complete	Da	Ne	60%	50	0.2586	0.2733	0.1741	0.4751	–

5.1 Optimalna konfiguracija modela

Rezultati prikazani u Tabeli 6 predstavljaju optimalne konfiguracije svakog od pet razmatranih modela prema Silhouette koeficijentu. Za svaki model izabrana je konfiguracija koja je ostvarila najveću vrednost ove metrike kroz sve ispitane kombinacije skupa podataka, filtriranja ripita, nivoa objašnjene varijanse i hiperparametara.

Tabela 6: Optimalne vrednosti hiperparametara za primenjene modele i skupove podataka.

Model	Skup	Hiperparametri modela
K-Means	All Sequences	<i>n_clusters</i> : 2 <i>init</i> : k-means++ <i>n_init</i> : 10 <i>max_iter</i> : 300 <i>random_state</i> : 34234
Agglomerative	All Sequences	<i>n_clusters</i> : 3 <i>linkage</i> : average <i>metric</i> : euclidean
BIRCH	All Sequences	<i>number_clusters</i> : 3 <i>diameter</i> : 0.3
DBSCAN	All Sequences	<i>eps</i> : 0.0030876377 <i>neighbors</i> : 3
CLIQUE	All Sequences	<i>amount_intervals</i> : 4 <i>density_threshold</i> : 1
K-Means	Complete Sequences	<i>n_clusters</i> : 2 <i>init</i> : k-means++ <i>n_init</i> : 10 <i>max_iter</i> : 300 <i>random_state</i> : 34234
Agglomerative	Complete Sequences	<i>n_clusters</i> : 2 <i>linkage</i> : ward <i>metric</i> : euclidean
BIRCH	Complete Sequences	<i>number_clusters</i> : 2 <i>diameter</i> : 0.1
DBSCAN	Complete Sequences	<i>eps</i> : 0.0050278427 <i>neighbors</i> : 3

Kao što je prikazano u tabeli 7, kod algoritma K-Means najbolji rezultat ostvaren je nad skupom All Sequences, uz prethodno uklanjanje ripita prema definisanim dužinama. PCA redukcijom zadržano je 5% ukupne varijanse, što odgovara kreiranju tri glavne komponente. Dobijeni Silhouette koeficijent iznosi 0.7829, što ukazuje na relativno jasno razdvajanje formiranih klastera.

Agglomerative Clustering ostvaruje nešto bolji rezultat od K-Means algoritma. Optimalna konfiguracija takođe koristi skup All Sequences, filtriranje ripita i tri PCA komponente koje objašnjavaju 5% varijanse. Silhouette koeficijent od 0.7950 pokazuje da je hijerarhijsko klasterovanje u ovoj konfiguraciji ostvarilo kvalitetniju separaciju klastera.

BIRCH ostvaruje najbolji rezultat na skupu All Sequences uz prethodno filtriranje ripita prema definisanim dužinama. PCA redukcijom zadržano je 5% ukupne varijanse. U ovoj konfiguraciji ostvaren je Silhouette koeficijent od 0.7974.

Za DBSCAN je najbolja konfiguracija dobijena na skupu Complete Sequences, bez uklanjanja kolona na osnovu dužine ripita. U ovom slučaju PCA je zadržao 40% objašnjene varijanse kroz 19 komponenti. Silhouette koeficijent iznosi 0.6077, što je niže u odnosu na rezultate K-Means, Agglomerative i BIRCH algoritama.

CLIQUE je najbolji rezultat ostvario na skupu All Sequences uz filtriranje ripita. Optimalna PCA reprezentacija zadržava 10% objašnjene varijanse, odnosno pet komponenti, pri čemu je ostvarena vrednost Silhouette koeficijenta 0.7004.

Tabela 7: Najbolji Silhouette koeficijent za fiksirane vrednosti objašnjene varijanse tokom upotrebe PCA algoritma.

Model	Skup	Drop	Var.	Komp.	Silhouette
K-Means	All Sequences	Da	5%	3	0.7829
Agglomerative	All Sequences	Da	5%	3	0.7950
BIRCH	All Sequences	Da	5%	3	0.7974
DBSCAN	Complete Sequences	Ne	40%	19	0.6077
CLIQUE	All Sequences	Da	10%	5	0.7004

5.2 Najznačajniji ripiti koji pripadaju klasterima određenim optimalnim konfiguracijama modela K-Means, Agglomerative i BIRCH nad skupom podataka koji sadrži sve sekvence

U tabelama 8, 9 i 10 prikazano je trideset najznačajnijih ripita izdvojenih primenom modela K-Means, Agglomerative i BIRCH nad skupom podataka koji sadrži sve sekvence. Ripiti su rangirani opadajuće prema vrednosti razlike između njihove lokalne i globalne zastupljenosti. *Globalna zastupljenost ripita* predstavlja odnos broja nukleotidnih sekvenci u kojima se dati ripit pojavljuje i ukupnog broja analiziranih nukleotidnih sekvenci, pri čemu se instance označene kao šum isključuju iz analize. *Lokalna zastupljenost ripita* predstavlja analogan odnos unutar konkretnog klastera. Veća pozitivna razlika između lokalne i globalne zastupljenosti ukazuje na veću specifičnost ripita za posmatrani klaster, odnosno na njegovu izraženiju zastupljenost u tom klasteru u odnosu na celokupan skup analiziranih nukleotidnih sekvenci.

Rezultati pokazuju visok stepen saglasnosti između analiziranih modela, budući da se među najznačajnijim ritima u sva tri slučaja pojavljuju iste ili veoma slične sekvence, poput AAAGAAAAGAAA, AAGAAAAAAGAA, AGAAGAAGAAGA i AAGGAA-AAGGAA. Ovakvo poklapanje ukazuje na stabilnost procesa klasterovanja i potvrđuje da navedeni ripiti predstavljaju dominantne obrasce koji karakterišu izdvojene grupe sekvenci.

Dodatno, može se uočiti da modeli Agglomerative i BIRCH ostvaruju veće vrednosti razlike zastupljenosti u odnosu na model K-Means. Na primer, najveća vrednost razlike zastupljenosti kod modela K-Means iznosi približno 0.005, dok kod modela Agglomerati-

ve i BIRCH dostiže vrednosti od oko 0.009. To sugerise da hijerarhijski pristupi uspešnije izdvajaju klastere sa izraženijim i specifičnijim obrascima ripita, što je u skladu sa prethodno dobijenim vrednostima Silhouette koeficijenta, gde su modeli Agglomerative i BIRCH ostvarili bolje rezultate od modela K-Means.

Tabela 8: Najznačajnijih trideset ripita za model K-Means nad skupom koji sadrži sve sekvence.

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
AAAGAAAAGAAA	0.246723	0.241710	0.005013
AAGAAAAAAGAA	0.237505	0.232680	0.004826
AGAAGAAGAAGA	0.236497	0.231692	0.004805
AAGGAAAAGGAA	0.231312	0.226612	0.004700
TATTATTATTAT	0.218493	0.214054	0.004440
AAAAAAAAAAAAA	0.216045	0.211655	0.004390
GAAAAGGAAAAG	0.192136	0.188232	0.003904
AGAAAAAAAAAGA	0.191128	0.187244	0.003884
ACAAAAAAAAACA	0.185799	0.182023	0.003775
AAAGAAAAAAGAAA	0.185655	0.181882	0.003772
AAAAGAAGAAAA	0.170964	0.167490	0.003474
AAAGGAAGGAAA	0.167075	0.163680	0.003395
TAGTAGGATGAT	0.164482	0.161140	0.003342
AAAACAACAAAA	0.163762	0.160435	0.003327
TATATATTATATAT	0.154112	0.150981	0.003131
TGAAAAAAAAAGT	0.149359	0.146324	0.003035
AAAAGTTGAAAA	0.148207	0.145195	0.003011
TAAAGAAGAAAT	0.145470	0.142514	0.002956
AAAATAATAAAA	0.142158	0.139269	0.002888
AAAAAAAAAAAAA	0.138989	0.136165	0.002824
AGAAATTAAAGA	0.137261	0.134472	0.002789
AAGTATTATGAA	0.136540	0.133766	0.002774

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
ATATATTATATA	0.132652	0.129956	0.002695
ATAAAAAAATA	0.132220	0.129533	0.002687
ACAACAACAACA	0.131499	0.128827	0.002672
TATAAAAAATAT	0.131355	0.128686	0.002669
ATGAAAAAAGTA	0.131211	0.128545	0.002666
TATATAATATAT	0.130635	0.127981	0.002654
TTAAAAAAAATT	0.130491	0.127840	0.002651
AAATATTATAAA	0.129483	0.126852	0.002631

Tabela 9: Najznačajnijih trideset ripita za model Agglomerative nad skupom koji sadrži sve sekvence.

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
AAAGAAAAGAAA	0.251394	0.241710	0.009684
AAGAAAAAAGAA	0.242002	0.232680	0.009322
AGAAGAAGAAGA	0.240974	0.231692	0.009283
AAGGAAAAGGAA	0.235691	0.226612	0.009079
TATTATTATTAT	0.222630	0.214054	0.008576
AAAAAAAAAAAAA	0.220135	0.211655	0.008480
GAAAAGGAAAAG	0.195773	0.188232	0.007541
AGAAAAAAAAGA	0.194746	0.187244	0.007502
ACAAAAAAAACA	0.189316	0.182023	0.007293
AAAGAAAAAAGAAA	0.189169	0.181882	0.007287
AAAAGAAGAAAA	0.174200	0.167490	0.006710
TTTTTTTTTTTTT	0.223951	0.217299	0.006651
AAAGGAAGGAAA	0.170238	0.163680	0.006558
TAGTAGGATGAT	0.167596	0.161140	0.006456
AAAACAACAAAA	0.166862	0.160435	0.006428

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
TATATATTATATAT	0.157030	0.150981	0.006049
TGAAAAAAAAAGT	0.152187	0.146324	0.005862
AAAAGTTGAAAA	0.151013	0.145195	0.005817
TAAAGAAGAAAT	0.148224	0.142514	0.005710
AAAATAATAAAA	0.144849	0.139269	0.005580
AGAAATTAAAGA	0.139859	0.134472	0.005388
AAGTATTATGAA	0.139125	0.133766	0.005359
AAAAAAAAAAAAAA	0.141473	0.136165	0.005309
ATATATTATATA	0.135163	0.129956	0.005207
ATAAAAAAATA	0.134723	0.129533	0.005190
ACAACAACAACA	0.133989	0.128827	0.005161
TATAAAAAATAT	0.133842	0.128686	0.005156
ATGAAAAAAGTA	0.133695	0.128545	0.005150
TATATAATATAT	0.133108	0.127981	0.005127
TTAAAAAAATTT	0.132962	0.127840	0.005122

Tabela 10: Najznačajnijih trideset ripita za model BIRCH nad skupom koji sadrži sve sekvence.

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
AAAGAAAAGAAA	0.251173	0.241710	0.009463
AAGAAAAAAGAA	0.241789	0.232680	0.009109
AGAAGAAGAAGA	0.240762	0.231692	0.009071
AAGGAAAAGGAA	0.235484	0.226612	0.008872
TATTATTATTAT	0.222434	0.214054	0.008380
AAAAAAAAAAAAAA	0.219941	0.211655	0.008286
GAAAAGGAAAAG	0.195601	0.188232	0.007369
AGAAAAAAAAGA	0.194575	0.187244	0.007331

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
ACAAAAAAAAACA	0.189150	0.182023	0.007126
AAAGAAAAAAGAAA	0.189003	0.181882	0.007121
TTTTTTTTTTTTTT	0.224047	0.217299	0.006748
AAAAGAAGAAAA	0.174047	0.167490	0.006557
AAAGGAAGGAAA	0.170088	0.163680	0.006408
TAGTAGGATGAT	0.167449	0.161140	0.006309
AAAACAACAAAA	0.166716	0.160435	0.006281
TATATATTATATAT	0.156891	0.150981	0.005911
TGAAAAAAAAAGT	0.152053	0.146324	0.005729
AAAAGTTGAAAA	0.150880	0.145195	0.005684
TAAAGAAGAAAT	0.148094	0.142514	0.005579
AAAATAATAAAA	0.144721	0.139269	0.005452
AGAAATTAAAGA	0.139736	0.134472	0.005265
AAGTATTATGAA	0.139003	0.133766	0.005237
AAAAAAAAAAAAAA	0.141349	0.136165	0.005184
ATATATTATATA	0.135044	0.129956	0.005088
ATAAAAAAATA	0.134604	0.129533	0.005071
ACAACAACAACA	0.133871	0.128827	0.005044
TATAAAAAATAT	0.133724	0.128686	0.005038
ATGAAAAAAGTA	0.133578	0.128545	0.005032
TATATAATATAT	0.132991	0.127981	0.005010
TTAAAAAAAATT	0.132845	0.127840	0.005005

5.3 Diskusija

Rezultati optimizacije hiperparametara pokazali su da izbor modela ima značajan uticaj na kvalitet dobijenih klastera. Među razmatranim modelima, BIRCH je ostvario najvišu vrednost Silhouette koeficijenta od 0.7974, dok je Agglomerative ostvario vrednost 0.7950, a K-Means 0.7829 nad skupom podataka koji sadrži sve sekvence, uz

primenu redukcije dimenzionalnosti kroz PCA algoritam. Ovi rezultati ukazuju da su navedeni modeli uspešno identifikovali strukturu podataka i formirali relativno kompaktne i međusobno dobro razdvojene klastere.

Posebno je značajna sličnost rezultata dobijenih primenom modela K-Means, Agglomerative i BIRCH. Analiza trideset najznačajnijih ripita pokazala je da se veliki broj istih sekvenci pojavljuje među najviše rangiranim ripitima za sva tri modela. Pri tome, Agglomerative i BIRCH ostvaruju veće razlike između lokalne i globalne zastupljenosti ripita u odnosu na K-Means, što sugerise na izraženiju specifičnost pojedinih ripita za posmatrane klastere. Saglasnost između modela može se posmatrati kao pokazatelj stabilnosti identifikovanih obrazaca, jer nezavisni algoritmi dolaze do sličnih zaključaka o karakterističnim ripitima.

Sa druge strane, rezultati DBSCAN i CLIQUE modela ukazuju na ograničenja primenjenih metoda u ovom problemu. Ovi modeli su za skup podataka koji sadrži sve sekvence ostvarili veoma nisku vrednost Silhouette koeficijenta. Jedan verovatan razlog bi bila sama činjenica da je prostor podataka smanjen tako da je zadržano svega 5 % varijanse, čime se odbacuje značajan deo skupa podataka. Drugi razlog bi bio način na koji ovi algoritmi određuju strukturu klastera. Za razliku od K-Means, Agglomerative i BIRCH pristupa, koji su pogodniji za strukture podataka prisutne u analiziranom skupu, DBSCAN i CLIQUE zahtevaju odgovarajući izbor parametara gustine i strukture prostora. Osetljivost ovih metoda na izbor hiperparametara može biti posebno izražena kod podataka visoke dimenzionalnosti ili kod podataka čija struktura nije jasno definisana lokalnim regionima gustine.

Dobijeni rezultati takođe ukazuju na značaj pretprocesiranja podataka. U eksperimentima je razmatrano smanjenje varijanse i različit broj komponenti, čime je omogućeno ispitivanje uticaja reprezentacije podataka na kvalitet klasterovanja. Dalja poboljšanja mogla bi se ostvariti primenom drugih tehnika redukcije dimenzionalnosti, kao što su Truncated-SVD ili t-SNE, uz pažljivu analizu njihovog uticaja na očuvanje relevantne strukture podataka. Takođe bi bilo korisno ispitati alternativne načine reprezentacije ripita koji bi mogli bolje da opišu njihove međusobne odnose.

Budući rad mogao bi dodatno da proširi eksperimentalnu analizu primenom drugih algoritama klasterovanja, kao što su Gaussian Mixture Models, Spectral Clustering, PROCLUS i drugi. Posebno bi bilo značajno ispitati metode koji ne pretpostavljaju unapred određeni broj klastera ili koje mogu da identifikuju složenije i nelinearne strukture u podacima. Pored toga, kombinovanje više tehnika pretprocesiranja i klasterovanja, kao i sistematska optimizacija hiperparametara, moglo bi dovesti do stabilnijih i interpretabilnijih rezultata.

Konačno, buduća istraživanja mogla bi da uključe i metode mašinskog učenja koje omogućavaju učenje reprezentacija sekvenci, čime bi se potencijalno prevazišla ograničenja ručno definisanih karakteristika zasnovanih na zastupljenosti ripita. Primena metoda kao što su autoenkoderi ili savremeni modeli za učenje reprezentacija sekvencijalnih podataka mogla bi omogućiti izdvajanje složenijih obrazaca koji nisu direktno vidljivi u trenutnoj reprezentaciji. Na taj način bi se moglo ispitati da li naučene reprezentacije dovode do bolje separacije klastera i preciznijeg identifikovanja karakterističnih ripita.

6 Zaključak

U ovom radu analizirane su ponavljajuće sekvence u genomima četiri vrste hantavirusa sa ciljem ispitivanja mogućnosti njihovog grupisanja primenom metoda nenadgledanog mašinskog učenja. Na osnovu izdvojenih ripita formirane su binarne matrice za svaki skup podataka, nakon čega su primenjene TF-IDF transformacija i PCA redukcija dimenzionalnosti.

Eksperimentalni rezultati pokazali su da su K-Means, Agglomerative i BIRCH ostvarili najbolje rezultate, pri čemu je BIRCH postigao najviši Silhouette koeficijent od 0.7974. Sličnost najznačajnijih ripita izdvojenih različitim modelima dodatno ukazuje na stabilnost identifikovanih obrazaca. DBSCAN i CLIQUE ostvarili su slabije rezultate, što sugerise na njihovu veću osetljivost na reprezentaciju podataka i izbor hiperparametara.

Dobijeni rezultati potvrđuju da analiza ponavljajućih sekvenci može predstavljati koristan pristup za otkrivanje strukturnih obrazaca i grupisanje genomskih sekvenci hantavirusa. Dalji rad može biti usmeren ka primeni alternativnih metoda redukcije dimenzionalnosti, drugih algoritama klasterovanja i naprednijih metoda za učenje reprezentacija bioloških sekvenci.

Literatura

- [1] Samia Afzal, Liaqat Ali, Anum Batool, Momina Afzal, Nida Kanwal, Nailah Ramesses, Muhammad Safdar, Atif Ahmad, and Jing Yang. Hantavirus: an overview and advancements in therapeutic approaches for infection. *Frontiers in Microbiology*, 14, 2023.
- [2] Xiaoting Liao, Weihong prestige Zhu, Jiahua Zhou, Han Li, Xiang Xu, Bing Zhang, and Xin Gao. Repetitive DNA sequence detection and its role in the human genome. *Communications Biology*, 6(1):2–10, 2023.
- [3] Richard Durbin, Sean R. Eddy, Anders Krogh, and Graeme Mitchison. *Biological Sequence Analysis: Probabilistic Models of Proteins and Nucleic Acids*. Cambridge University Press, Cambridge, 2012.
- [4] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [5] Michael Bowles. *Machine Learning in Python: Essential Techniques for Predictive Analysis*, volume 1. Wiley, 2015.
- [6] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. *Association for Computing Machinery*, pages 226–231, 1996.
- [7] Ian T. Jolliffe. Principal component analysis. *Springer Series in Statistics*, 1986.