

Analiza ponavljajućih sekvenci u nukleotidnim sekvencama hantavirusa preko klasterovanja

STEFAN JEVTIĆ MI241043

Ulazni podaci

Obradene vrste Hantavirusa:

- Hantaan virus (Orthohantavirus hantanense)
- Dobrava-Belgrade virus (Orthohantavirus dobravaense)
- Puumala virus (Orthohantavirus puumalaense)
- Sin Nombre virus (Orthohantavirus sinnombreense)

Podaci su preuzeti sa portala NCBI Virus

Korišćeni skupovi podataka

Korišćeni su sledeći skupovi podataka, preuzeti sa NCBI portala:

- All sequences – skup koji sadrži sve sekvence
- Complete sequences – skup koji sadrži samo kompletne sekvence

Preprocesiranje podataka

- Primena TF-IDF transformacije
- Eliminacija atributa određene dužine
- Redukcija dimenzionalnosti (PCA)

Korišćeni modeli klasterovanja

- K-Means
- Agglomerative Clustering
- BIRCH
- DBSCAN
- CLIQUE

Varijacija hiperparametara modela

Za oba skupa podataka izabrane su vrednosti hiperparametara iz sledećih opsega vrednosti:

- K-Means:
 - “n_clusters”: [2,3,4,6,8],
 - “init”: [k-means++],
 - “n_init”: [10],
 - “max_iter”: [300]
- Agglomerative Clustering:
 - “n_clusters”: [2,3,4,6,8],
 - “linkage”: [“ward”, “average”, “complete”]
 - “metric”: [“euclidean”, “cosine”]
- BIRCH:
 - “number_clusters”: [2,3,4,6,8],
 - “diameter”: [0.1, 0.3, 0.5],

Varijacija hiperparametara modela

- DBSCAN:
 - “eps”: <determined internally>,
 - “neighbors”: [3, 5, 10],
- CLIQUE:
 - “amount_intervals”: [3, 4],
 - “density_threshold”: [1, 2]

Metrike evaluacije kvaliteta modela

- Silueta koeficijent: $\text{score} = (b_i - a_i) / \max(a_i, b_i)$
- Davies Bouldin indeks: $\text{score} = 1/k * \sum \max((S_i + S_j) / M_{ij})$
- Calinski Harabasz indeks: $\text{score} = (\text{BSS} / (k-1)) / (\text{WSS} / (N-k))$

Optimalne vrednosti hiperparametara

Model	Skup	Hiperparametri modela
K-Means	All Sequences	<i>n_clusters</i> : 2 <i>init</i> : k-means++ <i>n_init</i> : 10 <i>max_iter</i> : 300 <i>random_state</i> : 34234
Agglomerative	All Sequences	<i>n_clusters</i> : 3 <i>linkage</i> : average <i>metric</i> : euclidean
BIRCH	All Sequences	<i>number_clusters</i> : 3 <i>diameter</i> : 0.3
DBSCAN	All Sequences	<i>eps</i> : 0.0030876377 <i>neighbors</i> : 3
CLIQUE	All Sequences	<i>amount_intervals</i> : 4 <i>density_threshold</i> : 1
K-Means	Complete Sequences	<i>n_clusters</i> : 2 <i>init</i> : k-means++ <i>n_init</i> : 10 <i>max_iter</i> : 300 <i>random_state</i> : 34234
Agglomerative	Complete Sequences	<i>n_clusters</i> : 2 <i>linkage</i> : ward <i>metric</i> : euclidean
BIRCH	Complete Sequences	<i>number_clusters</i> : 2 <i>diameter</i> : 0.1
DBSCAN	Complete Sequences	<i>eps</i> : 0.0050278427 <i>neighbors</i> : 3

Najbolje vrednosti Silhouette koeficijenta za svaki model

Model	Skup	Drop	Var.	Komp.	Silhouette
K-Means	All Sequences	Da	5%	3	0.7829
Agglomerative	All Sequences	Da	5%	3	0.7950
BIRCH	All Sequences	Da	5%	3	0.7974
DBSCAN	Complete Sequences	Ne	40%	19	0.6077
CLIQUE	All Sequences	Da	10%	5	0.7004

Određivanje najznačajnijih ripita za modele K-Means, Agglomerative i BIRCH

- Metrika: razlika između lokalne i globalne zastupljenosti ripita.
- Globalna zastupljenost: udeo sekvenci sa datim ripitom, bez šuma.
- Lokalna zastupljenost: udeo sekvenci sa datim ripitom unutar klastera.
- Veća pozitivna razlika: veća specifičnost ripita za dati klaster.

Deo najznačajnijih ripita za K-Means model nad skupom podataka koji sadrži sve sekvence

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
AAAGAAAAGAAA	0.246723	0.241710	0.005013
AAGAAAAAAGAA	0.237505	0.232680	0.004826
AGAAGAAGAAGA	0.236497	0.231692	0.004805
AAGGAAAAGGAA	0.231312	0.226612	0.004700
TATTATTATTAT	0.218493	0.214054	0.004440
AAAAAAAAAAAAA	0.216045	0.211655	0.004390
GAAAAGGAAAAG	0.192136	0.188232	0.003904
AGAAAAAAAAGA	0.191128	0.187244	0.003884

Deo najznačajnijih ripita za Agglomerative model nad skupom podataka koji sadrži sve sekvence

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
AAAGAAAAGAAA	0.251394	0.241710	0.009684
AAGAAAAAAGAA	0.242002	0.232680	0.009322
AGAAGAAGAAGA	0.240974	0.231692	0.009283
AAGGAAAAGGAA	0.235691	0.226612	0.009079
TATTATTATTAT	0.222630	0.214054	0.008576
AAAAAAAAAAAAA	0.220135	0.211655	0.008480
GAAAAGGAAAAG	0.195773	0.188232	0.007541
AGAAAAAAAAGA	0.194746	0.187244	0.007502

Deo najznačajnijih ripita za BIRCH model nad skupom podataka koji sadrži sve sekvence

Ripit	Lokalna zastupljenost	Globalna zastupljenost	Razlika zastupljenosti
AAAGAAAAGAAA	0.251173	0.241710	0.009463
AAGAAAAAAGAA	0.241789	0.232680	0.009109
AGAAGAAGAAGA	0.240762	0.231692	0.009071
AAGGAAAAGGAA	0.235484	0.226612	0.008872
TATTATTATTAT	0.222434	0.214054	0.008380
AAAAAAAAAAAAA	0.219941	0.211655	0.008286
GAAAAGGAAAAG	0.195601	0.188232	0.007369
AGAAAAAAAAGA	0.194575	0.187244	0.007331

Hvala na pažnji!

