

Univerzitet u Beogradu
Matematički fakultet



Stefan Jevtić

Analiza ponavljajućih sekvenci u nukleotidnim
sekvencama hantavirusa

seminarski rad

Beograd, 2026.

Sadržaj

1	Uvod	2
2	Metodologija i opis podataka	3
2.1	Filtriranje podataka	4
2.2	Izgradnja strukturnih kolona iz izlaza alata StatRepeats	4
2.3	Korišćeni skupovi podataka	5
3	Preprocesiranje	5
3.1	Eliminacija visokokorelisanih kolona	5
3.2	Skaliranje podataka	6
3.3	Uzorkovanje skupa podataka (SMOTE)	6
3.4	Redukcija dimenzionalnosti	7
3.5	Metodološki osvrt: Podela skupa podataka na particije	7
3.6	Klasterovanje nad celokupnim skupom podataka	8
4	Metodologija eksperimentalne evaluacije	9
4.1	Variranje hiperparametara na skupu all_sequences	10
4.2	Variranje hiperparametara na skupu complete_sequences	11
5	Rezultati i diskusija	12
5.1	Rezultati nad skupom all_sequences bez primene PCA	12
5.2	Rezultati nad skupom all_sequences uz PCA	14
5.3	Rezultati nad skupom complete_sequences bez primene PCA	15
5.4	Rezultati nad skupom complete_sequences uz PCA	17
5.5	Diskusija	18
6	Zaključak	19

1 Uvod

Hantavirusi predstavljaju grupu virusa koji prirodno inficiraju glodare i povremeno se prenose na ljude [1]. Infekcija kod ljudske populacije može rezultovati teškom kliničkom slikom i često smrtnim ishodom, pri čemu se manifestacije bolesti razlikuju u zavisnosti od genetskog tipa virusa i geografske lokacije. Na prostorima Amerike, infekcija dovodi do hantavirusnog kardiopulmonalnog sindroma (eng. *hantavirus cardiopulmonary syndrome* – HCPS), brzo progresivnog stanja koje pogađa pluća i srce. Sa druge strane, u Evropi i Aziji hantavirusi uzrokuju hemoragijsku groznicu sa bubrežnim sindromom (eng. *haemorrhagic fever with renal syndrome* – HFRS), koja prvenstveno oštećuje bubrege i krvne sudove.

U okviru ovog istraživanja analizirani su genetski podaci četiri vrste hantavirusa:

- *Hantaan virus* (lat. *Orthohantavirus hantanense*): Prvi izolovani virus iz ove grupe, koji se primarno povezuje sa teškim oblicima hemoragijske groznice sa bubrežnim sindromom. Prenosi se preko glodara domaćina i ima značajan epidemiološki uticaj u istočnoj Aziji
- *Dobrava-Belgrade virus* (lat. *Orthohantavirus dobravaense*): Glavni patogen u jugoistočnoj Evropi, sa posebnim žarištem u regionu Balkana, koji kod ljudi izaziva teške kliničke oblike HFRS-a uz visoku stopu smrtnosti
- *Puumala virus* (lat. *Orthohantavirus puumalaense*): Široko rasprostranjen u severnoj i srednjoj Evropi, odgovoran za blaže oblike endemskog HFRS-a, u medicinskoj literaturi poznatog kao *nephropathia epidemica*
- *Sin Nombre virus* (lat. *Orthohantavirus sinnombreense*): Endemska vrsta u Severnoj Americi, koja uzrokuje hantavirusni kardiopulmonalni sindrom sa izrazito nepovoljnim ishodom kod obolelih

Razlikovanje između navedenih vrsta hantavirusa može se uspešno postići analizom ponavljajućih sekvenci unutar njihovih nukleotidnih nizova. Ponavljajuće sekvence predstavljaju specifične kombinacije nukleotida koje se unutar genoma pojavljuju više puta [7]. Izračunavanjem strukturnih karakteristika ovih elemenata, kao što su njihova dužina, učestalost pojavljivanja, međusobna udaljenost i entropija, dobija se jedinstveni genomski potpis (eng. *genomic signature*) specifičan za svaku posmatranu vrstu.

U ovom radu razvijen je postupak za izdvajanje i analizu pomenutih ponavljajućih sekvenci, koji obuhvata kontrolisano preprocesiranje i filtriranje podataka u svrhu prime-
ne klasterovanja [5]. Kao ključna tehnika nenadgledanog mašinskog učenja, klasterovanje podrazumeva automatsku identifikaciju unutrašnjih struktura i grupisanje podataka na osnovu njihove matematičke sličnosti. Time se sekvence sa bliskim karakteristikama smeštaju u iste klastere, dok se međusobno različite instance razdvajaju, što omogućava otkrivanje skrivenih bioloških obrazaca bez oslanjanja na unapred definisane klase.

Empirijska analiza i vrednovanje predloženih algoritama sprovedeni su nad dva konačna skupa podataka, pri čemu opšti skup sadrži sve dostupne sekvence, dok redukovani skup obuhvata isključivo kompletne genome. Kompletne sekvence definišu se kao zapisi koji sadrže celokupan i neprekidan genomski niz datog virusa, bez nedostajućih delova

ili praznina u nukleotidnom lancu. Istraživanje obuhvata sistematsku optimizaciju hiperparametara kroz tehniku mrežne pretrage (eng. *Grid Search*) nad šest različitih modela nenadgledanog učenja, uz završnu interpretaciju i poređenje dobijenih rezultata.


2 Metodologija i opis podataka

Skupovi podataka korišćeni u ovom istraživanju preuzeti su u obliku FASTA datoteka, koje predstavljaju tekstualni standard u bioinformatici za skladištenje nukleotidnih sekvenci. Struktura FASTA formata je dvodelna: otpočinje linijom zaglavlja koja je označena znakom *>* i sadrži jedinstveni identifikator sekvence sa pratećim metapodacima, nakon čega sledi sam tekstualni niz nukleotidnih baza (A, C, G, T/U).

Metodologija ovog rada predstavljena je kao reproduktivan i modularan eksperimentalni tok, kako bi svaka faza obrade mogla nezavisno da se proverí, ponovi i unapredi. Poseban fokus stavljen je na uklanjanje izvora tehničkog šuma koji može narušiti kvalitet klasterovanja, kao i na očuvanje biološki relevantnog signala u završnom prostoru kolona.

Centralnu komponentu u fazi izdvajanja karakteristika čini algoritam *StatRepeats*, specijalizovani alat namenjen identifikaciji maksimalnih ponavljajućih sekvenci unutar nukleotidnih nizova. Ovaj algoritam omogućava detekciju četiri tipa repetitivnih elemenata: direktnih nekomplementarnih (*dn*), direktnih komplementarnih (*dc*), inverznih nekomplementarnih (*in*) i inverznih komplementarnih (*ic*) ponavljajućih sekvenci.

Primenom alata *StatRepeats* postignuta je precizna statistička selekcija, čime su iz skupova podataka izdvojene isključivo statistički značajne ponavljajuće sekvence filtrirane na osnovu zadate *p*-vrednosti, dok su dobijeni rezultati uspešno uobličeni i sačuvani za dalju analizu. Celokupan tok rada, od ulaznih FASTA sekvenci do vrednovanja klastera, prikazan je na Slici 1.



Slika 1: Konceptualni prikaz obradnog cevovoda korišćenog u radu, od sirovih sekvenci do završnog vrednovanja klasterovanja.

U implementacionom smislu, obradni tok je podeljen na tri programske celine: čišćenje sekvenci, izgradnju preprocesiranog skupa kolona i analitički eksperiment klasterovanja. Opisana modularnost olakšava izmenu ili zamenu pojedinačnih komponenti bez narušavanja stabilnosti ostatka sistema.

2.1 Filtriranje podataka

Najpre je bilo potrebno normalizovati FASTA zapise, pri čemu se svaka sekvencija prevodi u strogo kontrolisan alfabet nukleotida $\{A, C, G, T, U\}$. Time se eliminišu nestandardni simboli, prazne linije i strukturne nekonzistentnosti koje mogu izazvati greške prilikom obrade i dovesti do netačnog izdvajanja ponavljajućih sekvenci.

Ulazni podaci sadrže genomske sekvence klasifikovane u četiri prethodno opisane biološke vrste hantavirusa: *Orthohantavirus puumalaense*, *Orthohantavirus dobravaense*, *Orthohantavirus hantanense* i *Orthohantavirus sinnombreense*. Ograničavanje analize na ove taksonomske celine smanjuje varijabilnost skupa i omogućava primarni fokus na identifikaciju međusobnih razlika u strukturama ponavljajućih sekvenci.

Nakon čišćenja sekvenci, pokreće se pomoćna skripta koja generiše mapiranje između *Sequence_ID* identifikatora i zvaničnog naziva virusne vrste izolovanog iz FASTA zaglavlja. Ovaj korak je ključan jer obezbeđuje konzistentno i automatsko obeležavanje uzoraka tokom izgradnje skupova podataka, čime se minimizuje verovatnoća ljudske greške i osigurava potpuna ponovljivost eksperimenta.

2.2 Izgradnja strukturnih kolona iz izlaza alata StatRepeats

Sirovi tekstualni izlazi alata *StatRepeats* transformisani su u analitičke matrice kolona tako što su za svaku pojedinačnu sekvencu sračunati sledeći parametri: ukupan broj ponavljajućih sekvenci, njihova prosečna dužina, maksimalna zabeležena dužina, kao i raspodela frekvencija po dužinama. Na ovaj način dobijena je bogata numerička reprezentacija koja istovremeno obuhvata globalne i lokalne karakteristike virusnog genoma.

Konačna tabela kolona nastaje spajanjem četiri pomenute grupe analiza (*dn*, *dc*, *in*, *ic*) primenom ključa *Sequence_ID*. Pregled svih ključnih datoteka i njihove uloge u ovom procesu dat je u Tabeli 1.

Naziv datoteke	Tip	Uloga u cevovodu
<i>all_sequences.fasta</i>	ulaz	Primarne sirove sekvence različitog stepena kompletnosti.
<i>all_sequences_clean.fasta</i>	međufaza	FASTA zapis posle stroge validacije nukleotidnog alfabeta.
<i>all_dn.txt</i> , <i>all_dc.txt</i> , <i>all_in.txt</i> , <i>all_ic.txt</i>	međufaza	Strukturni izlazi alata <i>StatRepeats</i> za opšti skup sekvenci.
<i>dataset_all_sequences.csv</i>	izlaz	Konačna matrica kolona za eksperimentalnu analizu opšteg skupa.
<i>dataset_complete_sequences.csv</i>	izlaz	konačna matrica kolona za eksperimentalnu analizu kompletnog skupa.

Tabela 1: Pregled ključnih datoteka i njihove funkcionalne uloge u obradi podataka.

2.3 Korišćeni skupovi podataka

U ovom radu fokus je stavljen na identifikaciju unutrašnje strukture i grupisanje genomskih sekvenci različitih vrsta hantavirusa zasnovano na izdvajanju karakteristika njihovih ponavljajućih sekvenci. Razumevanje genomske organizacije kroz raspodelu kratkih i dugih ponavljajućih sekvenci pruža ključan uvid u evoluciju virusa, stabilnost genoma i potencijalne biološke srodnosti. U tom smislu, primena klasterovanja nad konačnim skupovima podataka omogućava otkrivanje skrivenih obrazaca i prirodnih grupisanja unutar sekvenci, bez oslanjanja na unapred definisane klase.

Za potrebe komparativne analize i evaluacije primenjene metode nenadgledanog mašinskog učenja, formirana su dva konačna skupa podataka izvedena iz bioinformatičke NCBI Virus baze. Prvi skup podataka, označen kao opšti skup sekvenci *all_sequences*, obuhvata parcijalne, fragmentisane i kompletne genomske sekvence, čime se testira otpornost klasterovanja na prisustvo tehničkog šuma. Drugi skup *complete_sequences* sadrži isključivo u potpunosti sekvencirane i verifikovane kompletne genome virusa, što omogućava preciznu analizu grupisanja na visokokvalitetnim biološkim podacima.

Kvantitativni uporedni prikaz oba konačna skupa dat je u Tabeli 2. Ova tabela jasno pokazuje da je skup *complete_sequences* manji i homogeniji, dok skup *all_sequences* poseduje veću raznovrsnost, što predstavlja izazov za definisanje jasnih granica među generisanim klasterima.

<i>Skup podataka</i>	<i>Uzoraka</i>	<i>Broj kolona</i>
<i>all_sequences</i>	6658	77
<i>complete_sequences</i>	417	71

Tabela 2: Uporedni pregled broja uzoraka i inicijalnih kolona po skupovima podataka.

3 Preprocesiranje

Pre primene algoritama klasterovanja, sproveden je proces pripreme podataka kako bi se sirovi bioinformatički zapisi preveli u oblik pogodan za modelovanje. U prvom koraku, iz oba skupa podataka eksplicitno je uklonjena kolona *Sequence_ID*, budući da jedinstveni identifikatori sekvenci ne nose nikakvu diskriminativnu biološku vrednost, a njihovo prisustvo bi veštački narušilo metričke odnose u prostoru karakteristika. Nakon toga, nad podacima su sukcesivno primenjene sledeće tehnike: eliminacija visokokorelisanih kolona, skaliranje vrednosti, naduzorkovanje manjinskih klasa, te redukcija dimenzionalnosti.

3.1 Eliminacija visokokorelisanih kolona

Cilj ovog koraka je uklanjanje redundantnih informacija. Ukoliko su dva kolona u visokoj korelaciji, oni nose gotovo identične informacije o genetskoj strukturi, što može numerički opteretiti modele i destabilizovati procenu rastojanja. Za detekciju linearnih zavisnosti upotrebljen je Pirsonov koeficijent korelacije. Prag korelacije predstavlja graničnu vrednost iznad koje se jedan od dva povezana kolona eliminiše iz daljeg toka obrade.

Za opšti skup podataka `all_sequences` postavljen je prag od 0.90 (izbacuju se atributi sa linearnom zavisnošću većom od 90%), čime je prostor kolona sveden na 58 kolona. Za skup kompletnih sekvenci, usled manje zapremine uzorka i potrebe za strožim filtriranjem multikolinearnosti, primenjen je restriktivniji prag od 0.75 i broj kolona je time smanjen na 44.

3.2 Skaliranje podataka

Budući da frekvencije i karakteristike ponavljajućih sekvenci mogu imati drastično različite opsege vrednosti, neophodno je izvršiti njihovu standardizaciju. U suprotnom, atributi sa nominalno većim vrednostima bi nerealno dominirali prilikom računanja euklidskih i drugih rastojanja. Za ovaj korak iskorišćen je *StandardScaler*. Ovaj algoritam transformiše podatke tako što njihovu srednju vrednost svodi na 0, a varijansu na 1. Na ovaj način, sve instance i atributi su dovedeni u sličan, uporediv opseg, čime je obezbeđen stabilan rad algoritama klasterovanja.

3.3 Uzorkovanje skupa podataka (SMOTE)

Distribucija virusnih vrsta u originalnim uzorcima izuzetno je neujednačena, što odražava realno stanje u javnim bazama gde su određene vrste hantavirusa znatno frekventnije sekvencirane od drugih. Veliki disbalans klasa može negativno uticati na formiranje klastera, jer algoritmi teže da ignorišu malobrojne grupe ili ih proglase šumom. Za rešavanje ovog problema primenjena je tehnika vetačkog generisanja uzoraka SMOTE (eng. *Synthetic Minority Over-sampling Technique*) [4].

U skupu `all_sequences`, distribucija instanci po vrstama pre i nakon primene SMOTE algoritma transformisana je na sledeći način:

- *Originalna distribucija klasa:*
 - Orthohantavirus puumalaense: 3562 uzorka
 - Orthohantavirus hantanense: 2056 uzoraka
 - Orthohantavirus dobravaense: 764 uzorka
 - Orthohantavirus sinnombreense: 276 uzoraka
- *Distribucija nakon SMOTE resamplovanja:*
 - Sve četiri navedene vrste su ujednačene na po 3562 uzorka.

Isti postupak je sproveden i nad skupom `complete_sequences`, gde je inicijalni disbalans bio još izraženiji:

- *Originalna distribucija klasa:*
 - Orthohantavirus hantanense: 242 uzorka
 - Orthohantavirus puumalaense: 117 uzoraka
 - Orthohantavirus dobravaense: 40 uzoraka

- Orthohantavirus sinnombreense: 18 uzoraka
- *Distribucija nakon SMOTE resamplovanja:*
 - Sve četiri navedene vrste su ujednačene na po 242 uzorka.

3.4 Redukcija dimenzionalnosti

Za mapiranje podataka u prostor niže dimenzionalnosti korišćen je algoritam analize glavnih komponenti *PCA*. Kod skupa `all_sequences`, *PCA* je konfigurisan tako da dinamički zadrži broj komponenti koji objašnjava kumulativno 95% ukupne varijanse podataka. Nasuprot tome, kod skupa `complete_sequences`, broj kolona je fiksno redukovan na tačno 4 dimenzije.

Ovakva restriktivna redukcija kod kompletnih sekvenci primenjena je sa ciljem direktne borbe protiv *prokletstva dimenzionalnosti* (eng. *Curse of Dimensionality*). Pomenuti fenomen se javlja kada se podaci analiziraju u visokodimenzionalnim prostorima, gde zapremina prostora raste eksponencijalno u odnosu na broj dimenzija. Usled toga, raspoloživi uzorci postaju izuzetno retki (udaljeni jedni od drugih), a koncepti kao što je Euklidsko rastojanje gube svoju diskriminativnu moć jer sve tačke postaju podjednako udaljene, što onemogućava efikasno klasterovanje. Redukcijom na 4 komponente, prostor je sažet, a topološke relacije su postale metrički smislene.

3.5 Metodološki osvrt: Podela skupa podataka na particije

U okviru ovog rada, radi vežbe i komparativne analize performansi, sprovedeno je standardno particionisanje skupa na particije za obučavanje, validaciju i testiranje. Za skup `all_sequences` dimenzije podskupova nakon podele su iznosile:

- *Skup za obučavanje:* X_{train} (5392, 58), y_{train} (5392,)
- *Validacioni skup:* X_{val} (600, 58), y_{val} (600,)
- *Test skup:* X_{test} (666, 58), y_{test} (666,)

Dok su kod skupa `complete_sequences` dimenzije iznosile:

- *Skup za obučavanje:* X_{train} (337, 44), y_{train} (337,)
- *Validacioni skup:* X_{val} (38, 44), y_{val} (38,)
- *Test skup:* X_{test} (42, 44), y_{test} (42,)

Iako je ovakvo particionisanje standardna i obavezna praksa kod *nadgledanog mašinskog učenja*, gde se na validacionom skupu podešavaju hiperparametri, a na test skupu vrši konačno poređenje, u kontekstu nenadgledanog mašinskog učenja ovo predstavlja neispravnu praksu.

Algoritmi zasnovani na gustini podataka, kao što su DBSCAN i HDBSCAN, ne uče funkciju preslikavanja, već direktno analiziraju topološki kontinuitet i lokalnu gustinu

tačaka u prostoru [6]. Deljenjem skupa na veštačke particije, prekinut je prostorni kontinuitet i drastično je smanjena gustina uzoraka po jedinici prostora. Pošto su ovi algoritmi obučavani i evaluirani nad skupovima veštački izmenjene i smanjene gustine, dobijeni su nerealni rezultati klasterovanja koji ne oslikavaju stvarnu strukturu podataka.

3.6 Klasterovanje nad celokupnim skupom podataka

Vođeni zaključkom o gubitku gustinske strukture usled particionisanja, implementiran je ispravan eksperimentalni režim u kojem su modeli obučavani nad celim, integralnim skupom podataka. Za ovu analizu pokrenuto je pet modela koji pripadaju različitim algoritamskim paradigmama [2, 3]:

- *K-Means* je primenjen kao referentni model zasnovan na particionisanju oko centroida. Algoritam iterativno određuje k , zadatih pre pokretanja algoritma, centroida sa ciljem minimizacije inercije unutar klastera, odnosno sume kvadratnih odstupanja tačaka od njima najbližeg centra. U ovom kontekstu, on služi za identifikaciju uniformnih, sfernih struktura unutar prostora kolona.
- *DBSCAN* (Density-Based Spatial Clustering of Applications with Noise) predstavlja model klasterovanja zasnovanom na gustini podataka, izuzetno značajan za analizu nad celim skupom podataka. Za razliku od *K-Means* modela, on ne zahteva unapred zadat broj klastera, već grupiše tačke na osnovu njihove prostorne bliskosti i lokalne gustine, pomoću parametara `eps` i `min_samples`. Ključna prednost mu je sposobnost izolovanja stohastičkog šuma, odnosno izbacivanja sekvenci koje ne pripadaju nijednoj stabilnoj evolucionoj grupi
- *Agglomerative Clustering* je iskorišćen kao predstavnik hijerarhijskog klasterovanja koji koristi „bottom-up” pristup. Algoritam počinje tako što svaki uzorak posmatra kao zaseban klaster, a zatim uzastopno spaja parove najbližih grupa na osnovu predefinisano g kriterijuma povezivanja, gde je *Ward-ov* metod upotrebljen za minimalno povećanje varijanse. Ovaj metod u svakom koraku spaja klastere tako da se minimizuje suma kvadratnih odstupanja, odnosno gubitak informacija. Time se obezbeđuje visoka homogenost i formiranje kompaktnih, sfernih grupa, što ovaj model čini idealnim za rekonstrukciju ugnježđenih topoloških odnosa, nalik filogenetskim stablima u bioinformatici
- *Spectral Clustering* je implementiran radi prepoznavanja kompleksnih, nelinearnih struktura koje standardni metrički modeli ne mogu uspešno da razdvoje. Ovaj algoritam koristi sopstvene vrednosti i vektore matrice afiniteta kako bi izvršio spektralnu dekompoziciju i projektovao podatke u prostor niže dimenzionalnosti pre samog particionisanja. Na taj način se mapira povezanost unutar grafa susedstva genomskih nizova
- *GMM* (Gaussian Mixture Models) predstavlja probabilistički model mešavine Gausovih raspodela. Za razliku od klasičnih metoda koje dodeljuju fiksnu pripadnost klasteru, GMM koristi *Expectation-Maximization* algoritam kako bi izračunao verovatnoću da određeni genomski uzorak pripada određenom klasteru. Ovo omogućava modelovanje elipsoidnih grupa promenljive orijentacije i veličine, što bolje odgovara prirodnim varijacijama u frekvencijama bioloških ponovaka

Izračunavanjem metrika nad kompletnim skupom dobijene su vrednosti koje su daleko realnije i stabilnije. DBSCAN je nad celim skupom uspešno detektovao neprekidne koridore gustine među nukleotidnim profilima, uspešno izolujući stvarni biološki šum od stabilnih grupacija. Istovremeno, K-Means i GMM su dali znatno pouzdanije pozicije centroida i kovarijacionih matrica jer su vršili procenu nad kompletnom geometrijom svih 6658 uzoraka, čime je neutralisana lokalna pristrasnost koja se javljala nad podskupovima.

4 Metodologija eksperimentalne evaluacije

Nakon završetka procesa preprocesiranja podataka, formiranja konačnih matrica kolona i opcione redukcije dimenzionalnosti primenom analize glavnih komponenti, sprovedena je eksperimentalna evaluacija algoritama za klasterovanje. Osnovni cilj ovog dela istraživanja bio je da se za svaki analizirani model identifikuje konfiguracija hiperparametara koja omogućava formiranje što kompaktnijih i međusobno bolje razdvojenih klastera, uz očuvanje njihove biološke interpretabilnosti.

Za razliku od problema nadgledanog mašinskog učenja, gde se kvalitet modela procenjuje poređenjem predikcija sa unapred poznatim klasnim oznakama, kod algoritama nenadgledanog učenja ne postoji referentna ciljna promenljiva koja bi omogućila direktno merenje uspešnosti modela. Zbog toga se izbor optimalnih hiperparametara mora zasnivati na internim evaluacionim metrikama koje procenjuju isključivo geometrijsku organizaciju podataka u prostoru kolona.

U ovom radu kao primarni kriterijum optimizacije izabran je *Silhouette* koeficijent. Ova metrika predstavlja jednu od najčešće korišćenih mera kvaliteta klasterovanja, budući da istovremeno vrednuje kompaktnost instanci unutar istog klastera i razdvojenost između klastera. Za svaku instancu računa se prosečno rastojanje do svih tačaka unutar sopstvenog klastera, kao i najmanje prosečno rastojanje do susednog klastera. Na osnovu ova dva rastojanja dobija se *Silhouette* vrednost iz intervala $[-1, 1]$, pri čemu vrednosti bliske jedinici ukazuju na jasno razdvojene i kompaktne klasterove, vrednosti oko nule ukazuju na preklapanje grupa, dok negativne vrednosti predstavljaju indikator pogrešne dodele instanci.

Iako je *Silhouette* koeficijent korišćen kao osnovni kriterijum za izbor optimalnih hiperparametara, svaka dobijena konfiguracija dodatno je analizirana primenom Davies–Bouldin i Calinski–Harabasz indeksa. Davies–Bouldin indeks meri odnos između unutrašnje disperzije klastera i njihove međusobne udaljenosti, pri čemu manje vrednosti označavaju kvalitetnije klasterovanje. Sa druge strane, Calinski–Harabasz indeks procenjuje odnos međuklasterne i unutarklasterne disperzije, pri čemu veće vrednosti ukazuju na bolje razdvojene grupe. Kombinovanom analizom ove tri metrike obezbeđena je objektivnija procena kvaliteta dobijenih rešenja nego što bi to bilo moguće korišćenjem samo jedne evaluacione mere.

Kako bi se izbegao subjektivan izbor hiperparametara, optimizacija svih modela sprovedena je primenom tehnike mrežne pretrage. Ova metoda podrazumeva definisanje diskretnog prostora mogućih vrednosti hiperparametara za svaki algoritam, nakon čega se sistematski ispituju sve njihove kombinacije. Za svaku konfiguraciju model se izvršava nad kompletnim skupom podataka, izračunavaju se evaluacione metrike, a kao optimal-

no rešenje bira se konfiguracija koja ostvaruje najveću vrednost Silhouette koeficijenta. Ovakav pristup eliminiše potrebu za ručnim podešavanjem parametara i obezbeđuje re-produktivnost eksperimenta.

Pored evaluacije nad originalnim prostorom kolona, kompletna optimizacija sprovedena je i nakon primene PCA transformacije. Na taj način omogućeno je poređenje ponašanja svakog algoritma u visokodimenzionalnom prostoru i u prostoru smanjene dimenzionalnosti, čime je analiziran uticaj redukcije dimenzionalnosti na kvalitet formiranih klastera.

4.1 Variranje hiperparametara na skupu `all_sequences`

Za skup podataka `all_sequences` definisan je prostor hiperparametara prikazan u Tabeli 3. Prilikom određivanja opsega hiperparametara vođeno je računa da prostor pretrage bude dovoljno širok da obuhvati različite režime rada svakog algoritma, ali i dovoljno ograničen kako bi se izbegao nepotrebno veliki broj kombinacija koje ne doprinose poboljšanju rezultata.

Model	Varirani hiperparametri
K-Means	<i>init</i> = <code>{k-means++}</code> , <i>n_init</i> = <code>{10,20,50}</code>
DBSCAN	<i>eps</i> = <code>{0.2, 0.4, 0.6, 0.8, 1.0}</code> , <i>min_samples</i> = <code>{20,40,80}</code> , <i>metric</i> = <code>{euclidean, manhattan}</code>
Agglomerative Clustering	<i>linkage</i> = <code>{ward, average, complete}</code>
Spectral Clustering	<i>affinity</i> = <code>{nearest_neighbors, rbf}</code> , <i>n_neighbors</i> = <code>{20,40,60}</code>
Gaussian Mixture Models	<i>covariance_type</i> = <code>{full, diag, tied, spherical}</code>

Tabela 3: Prostor hiperparametara korišćen tokom optimizacije modela na skupu `all_sequences`.

Kod algoritma K-Means optimizovan je broj inicijalizacija centroida *n_init*, dok je način inicijalizacije fiksiran na strategiju *k-means++*, koja omogućava stabilnije određivanje početnih centroida i smanjuje verovatnoću konvergencije ka lokalnom optimumu. Za hijerarhijsko klasterovanje analizirane su tri različite strategije povezivanja: *ward*, *average* i *complete*, budući da izbor kriterijuma spajanja direktno određuje geometriju formiranih hijerarhijskih struktura.

Kod modela Gaussian Mixture Models analizirani su različiti tipovi matrica kovarijancije kako bi se ispitalo u kojoj meri pretpostavljena geometrija Gausovih komponenti utiče na kvalitet klasterovanja genomskih podataka. Time je omogućeno poređenje između modela koji pretpostavljaju sferne raspodele i modela koji dozvoljavaju punu kovarijacionu strukturu.

U okviru optimizacije algoritma DBSCAN, prostor pretrage je definisan variranjem hiperparametra *eps* kroz vrednosti 0.2, 0.4, 0.6, 0.8 i 1.0. Pored toga, kontrolisan je i hiperparametar *min_samples*, koji određuje minimalan broj susednih uzoraka potrebnih za generisanje jezgra klastera, kao i sama metrika za računanje prostorne bliskosti sekvenci.

Sličan postupak je primenjen i kod algoritma Spectral Clustering. Hiperparametar

$n_neighbors$ određuje broj susednih instanci koje učestvuju u konstrukciji grafa afiniteta. Male vrednosti ovog hiperparametra dovode do fragmentacije grafa i pojave velikog broja slabo povezanih komponenti, usled čega algoritam može izdvojiti veštačke klastere koji predstavljaju posledicu lokalnih varijacija u podacima. Iz tog razloga analizirane su vrednosti (20, 40 i 60), čime je obezbeđena stabilnija aproksimacija lokalne geometrije prostora i pouzdanije formiranje klastera.

4.2 Variranje hiperparametara na skupu `complete_sequences`

Za skup `complete_sequences` definisan je drugačiji prostor hiperparametara, prilagođen njegovim karakteristikama. Za razliku od prethodnog skupa, ovde je broj uzoraka višestruko manji, dok su sekvence homogenije i sadrže manji nivo tehničkog šuma. Iz tog razloga nije bilo opravdano koristiti identične opsege hiperparametara.

Kod algoritma K-Means smanjen je broj analiziranih vrednosti hiperparametra n_init , budući da se kod manjeg broja instanci stabilizacija centroida postiže znatno brže. Kod GMM modela razmatrane su samo dve konfiguracije kovarijacionih matrica koje su se u preliminarnim eksperimentima pokazale kao najstabilnije.

Za DBSCAN je zadržana podrazumevana vrednost hiperparametra eps , dok su dodatno povećane vrednosti hiperparametra $min_samples$ (30, 60 i 120). Na ovaj način algoritam je podstaknut da formira isključivo dovoljno velike i stabilne klastere, čime je smanjena mogućnost da mali broj međusobno bliskih sekvenci bude pogrešno interpretiran kao zasebna biološka grupa.

U okviru algoritma Spectral Clustering korišćene su vrednosti hiperparametra $n_neighbors$ (20, 40 i 80). Ovakav izbor omogućava formiranje robusnijeg grafa afiniteta i smanjuje osetljivost algoritma na slučajne lokalne promene u raspodeli podataka, što je naročito značajno kod skupova sa manjim brojem instanci.

Treba naglasiti da opsezi hiperparametara prikazani u ovom radu nisu određeni proizvoljno. Pre definisanja konačnih parametarskih mreža izvršen je veliki broj preliminarnih eksperimenata u kojima su analizirani znatno širi intervali mogućih vrednosti. Na osnovu dobijenih rezultata eliminisane su konfiguracije koje nisu doprinosile poboljšanju kvaliteta klasterovanja, nakon čega su definisani konačni prostori pretrage prikazani u Tabeli 4. Na taj način postignut je kompromis između sveobuhvatne optimizacije i prihvatljivog vremena izvršavanja eksperimenata.

Model	Varirani hiperparametri
K-Means	$init=\{\text{k-means}++\}$, $n_init=\{5,10\}$
DBSCAN	$eps=0.5$ (podrazumevano), $min_samples=\{30,60,120\}$, $metric=\{\text{euclidean}, \text{manhattan}, \text{cosine}\}$
Agglomerative Clustering	$linkage=\{\text{ward}, \text{average}, \text{complete}\}$
Spectral Clustering	$affinity=\{\text{nearest_neighbors}, \text{rbf}\}$, $n_neighbors=\{20,40,80\}$
Gaussian Mixture Models	$covariance_type=\{\text{spherical}, \text{full}\}$

Tabela 4: Parametarski prostor korišćen tokom optimizacije modela na skupu complete_sequences.

5 Rezultati i diskusija

U ovom poglavlju prikazani su rezultati evaluacije pomenutih algoritama klasterovanja nad skupovima podataka all_sequences i complete_sequences. Za oba skupa izvršena je analiza bez redukcije dimenzionalnosti i sa njenom primenom. Kvalitet klasterovanja procenjen je korišćenjem Silhouette, Davies–Bouldin i Calinski–Harabasz metrika.

Na osnovu dobijenih rezultata može se uočiti da skup podataka all_sequences u gotovo svim eksperimentima ostvaruje bolje vrednosti evaluacionih metrika u odnosu na skup complete_sequences. Ovo ukazuje da broj instanci i gustina skupa podataka značajno utiču na mogućnost algoritama da identifikuju prirodnu strukturu podataka. Posebno se izdvajaju rezultati algoritama DBSCAN i Agglomerative Clustering nad skupom all_sequences, koji ostvaruju veoma visoke vrednosti Silhouette koeficijenta i niske vrednosti Davies–Bouldin indeksa.

Formirani klasteri su prikazani u dve dimenzije koristeći t-SNE algoritam. Algoritam t-SNE (engl. *t-Distributed Stochastic Neighbor Embedding*) [8] primenjen je kao nelinearna tehnika za redukciju dimenzionalnosti sa primarnim ciljem vizuelne validacije donetih particija. Za razliku od linearnih transformacija, ovaj algoritam mapira visokodimenzionalne strukture u dvodimenzionalni prostor tako što minimizuje nesklad između uslovnih verovatnoća bliskosti tačaka u izvornom i ciljnom prostoru preko Kulbak–Lajblerove divergencije. Upotrebom t-distribucije u prostoru niske dimenzionalnosti, t-SNE uspešno rešava problem zagušenja i omogućava očuvanje lokalnih topoloških odnosa i finih granica između vrsta hantavirusa, što rezultujući raspored na grafiku čini direktnim indikatorom separabilnosti formiranih grupa.


5.1 Rezultati nad skupom all_sequences bez primene PCA

Kao što se može videti sa tabele 5 i grafika 2. Najveću vrednost Silhouette koeficijenta ostvario je model DBSCAN, čiji je Silhouette koeficijent povećan sa 0.6387 na 0.9060, uz značajno smanjenje Davies–Bouldin indeksa. Agglomerative Clustering je zadržao veoma visok kvalitet grupisanja, dok je Spectral Clustering ostvario primetno poboljšanje.


Na slici 3 je prikazan rezultat formiranja klastera u dve dimenzije koristeći t-SNE algoritam.

<i>Algoritam</i>	<i>Silhouette</i>	<i>Davies-Bouldin</i>	<i>Calinski-Harabasz</i>
K-Means	0.4629	1.1132	2310.8408
DBSCAN	0.6387	0.2669	22152.1938
Agglomerative	0.9116	0.0960	816.9720
Spectral	0.6235	2.3153	61.8328
Gaussian Mixture	0.4603	1.0347	2266.3506

Tabela 5: Rezultati ostvareni nad skupom all_sequences bez primene PCA modifikacije.



Slika 2: Grafik Silhouette koeficijenta za modele na skupu all_sequences bez primene PCA algoritma



Slika 3: Kreirani klasteri u dve dimeznije koristeći t-SNE algoritam na skupu all_sequences bez primene PCA algoritma


5.2 Rezultati nad skupom all_sequences uz PCA

Redukcija dimenzionalnosti kroz primenu algoritma analize glavnih komponenti, dodatno je unapredila rezultate pojedinih algoritama, kao što se može videti sa tabele 6 i grafika 4. Najveće poboljšanje ostvario je model DBSCAN, čiji je Silhouette koeficijent povećan sa 0.6387 na 0.9060, uz značajno smanjenje Davies–Bouldin indeksa. Agglomerative Clustering je zadržao veoma visok kvalitet grupisanja, dok je Spectral Clustering ostvario primetno poboljšanje.

Ipak, iako je Silhouette koeficijent za model DBSCAN izuzetno visok, detaljnija analiza preostale dve metrike ukazuje na to da ovaj model nije najoptimalnije rešenje za posmatrani skup podataka. Naime, ekstremno visoka i potencijalno distorzirana vrednost Calinski-Harabasz indeksa kod DBSCAN modela posledica je njegove osetljivosti na gustinu i izbacivanje velikog broja uzoraka u kategoriju šuma, čime se veštački smanjuje unutrašnja varijansa preostalih kompaktnih jezgara. Sa druge strane, hijerarhijsko klasterovanje ostvaruje stabilniji i prirodno balansiran Calinski-Harabasz koeficijent, uz zadržavanje maksimalne Silhouette vrednosti 0.9131. Budući da ovaj model uspešno i uniformno raspoređuje kompletan genomski prostor bez potrebe za agresivnim odbacivanjem sekvenci, on se preferira kao strukturno najpouzdaniji izbor za ovaj skup podataka.


<i>Algoritam</i>	<i>Silhouette</i>	<i>Davies-Bouldin</i>	<i>Calinski-Harabasz</i>
K-Means	0.4843	1.0692	2466.6425
DBSCAN	0.9060	0.1409	1722112.2695
Agglomerative	0.9131	0.2281	832.9889
Spectral	0.8053	2.0530	148.0341
Gaussian Mixture	0.4691	1.7821	1973.3690

Tabela 6: Rezultati ostvareni nad skupom all_sequences uz primenu PCA modifikacije.



Slika 4: Grafik Silhouette koeficijenta za modele na skupu all_sequences uz primenu PCA algoritma

Na slici 5 je prikazan rezultat formiranja klastera u dve dimenzije koristeći t-SNE algoritam.



Slika 5: Kreirani klasteri u dve dimenzije koristeći t-SNE algoritam na skupu `all_sequences` uz primenu PCA algoritma

5.3 Rezultati nad skupom `complete_sequences` bez primene PCA


Kao što se može videti sa tabele 7 i grafika 6. Rezultati nad ovim skupom podataka značajno su slabiji u poređenju sa skupom `all_sequences`. Model DBSCAN nije uspeo da pronađe odgovarajuću strukturu klastera za odabrane vrednosti hiperparametara usled proređenosti prostora, dok je Agglomerative Clustering ostvario najbolje rezultate među posmatranim algoritmima.

Posebno je važno istaći numeričko ponašanje modela DBSCAN, čije su vrednosti za sva tri evaluaciona koeficijenta eksplicitno pale na nulu. Ovaj ishod je direktna posledica evaluacione logike unutar implementiranog programskog koda za računanje metričkog odziva. Naime, algoritam je konfigurisan tako da pre računanja metrika najpre izoluje uzorke koji nisu proglašeni za šum, a potom identifikuje broj jedinstvenih klastera među njima. Ukoliko je broj tako formiranih, validnih grupa strogo manji od dva, funkcija automatski prekida dalji proračun i vraća vrednost nula, budući da metričke evaluacije poput Silhouette ili Davies–Bouldin indeksa nemaju smisla ako ne postoje barem dve nezavisne celine između kojih se meri rastojanje. U ovom konkretnom eksperimentu, usled prokletstva dimenzionalnosti i niske gustine uzoraka u izvornom prostoru od 44 dimenzije, DBSCAN je sve instance klasifikovao kao stohastički šum, ostavljajući skup bez ijednog stabilnog jezgra, što je rezultovalo nulovanjem svih performansi.


Na slici 7 je prikazan rezultat formiranja klastera u dve dimenzije koristeći t-SNE algoritam.

<i>Algoritam</i>	<i>Silhouette</i>	<i>Davies-Bouldin</i>	<i>Calinski-Harabasz</i>
K-Means	0.1869	1.8576	99.9457
DBSCAN	0.0000	0.0000	0.0000
Agglomerative	0.6339	0.2561	11.7028
Spectral	0.6173	1.8105	10.5970
Gaussian Mixture	0.1199	2.6945	51.4447

Tabela 7: Rezultati ostvareni nad skupom `complete_sequences` bez primene PCA modifikacije.



Slika 6: Grafik Silhouette koeficijenta za modele na skupu `complete_sequences` bez primene PCA algoritma




Slika 7: Kreirani klasteri u dve dimenzije koristeći t-SNE algoritam na skupu `complete_sequences` bez primene PCA algoritma

5.4 Rezultati nad skupom complete_sequences uz PCA

Kao što se može videti sa tabele 8 i grafika 8. Primena PCA značajno je unapredila rezultate svih algoritama nad skupom complete_sequences. Posebno se izdvaja model DBSCAN, koji je od neuspešnog grupisanja bez PCA ostvario Silhouette koeficijent od 0.7517 nakon redukcije dimenzionalnosti. Takođe, K-Means i Gaussian Mixture Models ostvarili su značajno bolje rezultate nego u originalnom prostoru kolona.


<i>Algoritam</i>	<i>Silhouette</i>	<i>Davies-Bouldin</i>	<i>Calinski-Harabasz</i>
K-Means	0.4851	0.8588	635.3472
DBSCAN	0.7517	0.2260	800.3796
Agglomerative	0.4814	0.6240	240.6563
Spectral	0.4470	0.4750	159.5978
Gaussian Mixture	0.4554	0.9250	583.1096

Tabela 8: Rezultati ostvareni nad skupom complete_sequences uz primenu PCA modifikacije.



Slika 8: Grafik Silhouette koeficijenta za modele na skupu complete_sequences uz primenu PCA algoritma

Na slici 9 je prikazan rezultat formiranja klastera u dve dimenzije na skupu complete_sequences koristeći t-SNE algoritam.



Slika 9: Kreirani klasteri u dve dimenzije koristeći t-SNE algoritam na skupu `complete_sequences` uz primenu PCA algoritma

5.5 Diskusija

Hiperparametri su menjani kroz više eksperimenata, pri čemu su za svaku konfiguraciju izračunate evaluacione metrike. Konačne vrednosti hiperparametara odabrane su na osnovu najboljeg kompromisa između visokog Silhouette koeficijenta, niskog Davies–Bouldin indeksa i visokog Calinski–Harabasz indeksa.

Dobijeni rezultati pokazuju da primena PCA uglavnom pozitivno utiče na kvalitet klasterovanja. Redukcija dimenzionalnosti uklanja deo redundantnih i međusobno korelisanih karakteristika, čime se olakšava identifikacija prirodne strukture podataka. Ovo je naročito izraženo kod algoritma DBSCAN, koji pokazuje značajno poboljšanje nakon primene PCA.

Poređenjem dva analizirana skupa podataka može se zaključiti da skup `all_sequences` poseduje pogodniju raspodelu karakteristika za primenu algoritama klasterovanja. U svim eksperimentima ostvarene su veće vrednosti Silhouette koeficijenta i niže vrednosti Davies–Bouldin indeksa nego kod skupa `complete_sequences`. To ukazuje da način formiranja ulaznog skupa podataka ima značajan uticaj na uspešnost nenadgledanog učenja.

Budući radovi bi se mogli fokusirati na pronalazak drugačijih vrednosti navedenih hiperparametara tako da se ostvare pogodnije vrednosti metrika. Na primer, za skup `complete_sequences` bez primene PCA, pronađene optimalne vrednosti hiperparametara modela DBSCAN uzrokuju da metrike postanu 0, što ostavlja prostora za unapređenje.

6 Zaključak

U ovom radu sprovedena je sveobuhvatna komparativna analiza pet naprednih algoritama klasterovanja u cilju identifikacije prirodnih i biološki relevantnih struktura unutar genomskih sekvenci hantavirusa. Evaluacija uspešnosti modela izvršena je kroz četiri eksperimentalne faze, variranjem dva skupa podataka `all_sequences` i `complete_sequences` u izvornom prostoru i prostoru smanjene dimenzionalnosti.

Kroz sve posmatrane faze, eksperimentalni rezultati nedvosmisleno pokazuju da izbor i način formiranja ulaznog skupa podataka, kao i gustina instanci u prostoru kolona, imaju kritičan uticaj na performanse nenadgledanog učenja. Skup podataka `all_sequences` je u svim konfiguracijama demonstrirao superiorne vrednosti evaluacionih metrika u odnosu na proređeni skup `complete_sequences`, na kome je model DBSCAN bez preprocesiranja doživeo pad performansi usled prokletstva dimenzionalnosti. Pored toga, potvrđen je pozitivan uticaj primene analize glavnih komponenti, koja je uspešno uklonila redundantne i korelisane karakteristike, omogućivši algoritmima preciznije postavljanje granica između klastera.

Uzimajući u obzir sve evaluacione kriterijume, najbolji ukupni rezultati ostvareni su nad skupom `all_sequences` uz primenu PCA algoritma za redukciju dimenzionalnosti. Unutar ove faze, kao najoptimalnije rešenje izdvojio se model hijerarhijskog klasterovanja. Iako je mrežnom pretragom hiperparametara algoritam DBSCAN u istoj fazi zabeležio prividno visok Silhouette koeficijent (0.9060), detaljna analiza strukture particija i eksplozija vrednosti Calinski–Harabasz indeksa ukazale su na anomaliju veštačkog smanjenja unutrašnje varijanse usled agresivnog odbacivanja sekvenci u kategoriju stohastičkog šuma. Sa druge strane, Agglomerative Clustering (uz podešavanje *linkage=average*) ostvario je maksimalnu vrednost Silhouette koeficijenta od 0.9131 i stabilan, prirodno balansiran Davies–Bouldin i Calinski–Harabasz odziv. Ovaj model je uspešno i uniformno grupisao kompletan genomski prostor bez gubitka informacija, što je vizuelno potvrđeno i kroz nelinearno mapiranje t-SNE algoritmom.

Buduća istraživanja u ovoj oblasti mogu se usmeriti ka proširivanju prostora hiperparametara za proređene skupove podataka, testiranju alternativnih nelinearnih tehnika za redukciju dimenzionalnosti, kao i dubljoj biološkoj validaciji identifikovanih klastera u svrhu taksonomske klasifikacije novootkrivenih sojeva hantavirusa.

Literatura

- [1] Samia Afzal, Liaqat Ali, Anum Batool, Momina Afzal, Nida Kanwal, Nailah Ramesses, Muhammad Safdar, Atif Ahmad, and Jing Yang. Hantavirus: an overview and advancements in therapeutic approaches for infection. *Frontiers in Microbiology*, 14, 2023.
- [2] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [3] Michael Bowles. *Machine Learning in Python: Essential Techniques for Predictive Analysis*, volume 1. Wiley, 2015.
- [4] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.

- [5] Richard Durbin, Sean R. Eddy, Anders Krogh, and Graeme Mitchison. *Biological Sequence Analysis: Probabilistic Models of Proteins and Nucleic Acids*. Cambridge University Press, Cambridge, 2012.
- [6] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. pages 226–231, 1996.
- [7] Xiaoting Liao, Weihong prestige Zhu, Jiahua Zhou, Han Li, Xiang Xu, Bing Zhang, and Xin Gao. Repetitive DNA sequence detection and its role in the human genome. *Communications Biology*, 6(1):2–10, 2023.
- [8] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, 9:2579–2605, 2008.